

Online Retail II EDA

Índice

1. Introducción	3
1.1. Motivación	3
1.2. Justificación	3
1.3. Objeto de estudio	3
1.4. Problema de investigación	3
1.4.1. Problema general	3
1.5. Objetivos	4
1.5.1. Objetivo general	4
1.5.2. Objetivos específicos	4
1.6. Hipótesis	4
1.6.1. Hipótesis específicas	4
2. Descripción General del Dataset	5
2.1. ¿Podemos describir qué es un registro?	5
2.2. ¿Cuántos registros existen?	5
2.3. ¿Son pocos o demasiados registros?	5
2.4. ¿Qué representa cada fila?	5
2.5. ¿Cuáles son los tipos de datos de cada columna?	6
2.6. ¿Es una data etiquetada?, ¿cómo se interpreta la información de las clases?	6
2.7. ¿Hay niveles de granularidad de los datos?	7
2.8. ¿Los datos tienen diferentes unidades de medida?	7
3. Limpieza de los datos	8
3.1. ¿Existen datos duplicados?	8
3.2. ¿Están todas las filas completas o tenemos campos con valores nulos?	9
3.3. En caso que haya demasiados nulos: ¿Queda el resto de información útil?	9
3.4. Hipótesis 1 - Concatenación de CustomerID	10
3.5. Acciones frente a los datos nulos	15
3.6. ¿Todos los datos están en su formato adecuado?	16
3.7. Análisis de outliers	20
3.7.1. ¿Cuáles son los Outliers?	20
3.7.2. ¿Podemos eliminarlos? ¿Es importante conservarlos?	22
4. Exploración	23
4.1. ¿Cuántos productos, clientes y países existen?	23
4.2. ¿Cuáles son los productos más vendidos?	23
4.3. ¿Cuáles son los productos más vendidos por cantidad?	24
4.4. ¿Siguen alguna distribución?	24
4.5. ¿Entre qué rangos están los datos?	25
4.6. ¿Cuál es la tendencia diaria de ventas?	30
4.7. ¿Cuál es la tendencia mensual de ventas?	32
4.8. ¿Cuál es el número de transacciones por horas?	34
4.9. ¿Cuáles son los productos más vendidos por país?	36
4.10. ¿Cuáles son los clientes con mayor y menor monto total de compra?	37

4.11. ¿Cómo se distribuyen las compras totales por país?	39
4.12. ¿Cómo evoluciona la retención de clientes a lo largo del tiempo?	39
4.13. ¿Cuál es la cantidad promedio de productos comprados por cohorte trimestral?	41
4.14. ¿Existe correlación entre cantidad, precio unitario y monto total de compra?	42
4.15. ¿Cómo se relaciona la cantidad comprada con el monto total según el país de origen?	44
4.16. Hipótesis 2 - Anomalías Geográficas en Patrones de Compra	47
4.17. Hipótesis 3 - Patrones Temporales de Compra	64
 5. Conclusiones Generales	 86

1. Introducción

1.1. Motivación

El comercio electrónico ha revolucionado la relación entre empresas y consumidores, generando volúmenes masivos de datos transaccionales cada día. Sin embargo, los datos por sí solos no generan valor: es su análisis inteligente lo que permite descubrir insights accionables.

Este proyecto nace del interés por aplicar técnicas avanzadas de inteligencia de negocios y minería de datos en un escenario real y desafiante.

El dataset ***Online Retail II*** ofrece la oportunidad única de trabajar con información transaccional auténtica que refleja comportamientos reales de compra, permitiéndome desarrollar competencias analíticas mientras genero conocimiento aplicable a cualquier negocio de e-commerce que busque mejorar su competitividad y retención de clientes.

1.2. Justificación

Este proyecto se justifica por su triple impacto:

- **Valor empresarial:** La segmentación efectiva de clientes mejora la retención y efectividad del marketing, identificando patrones de compra que anticipan necesidades y optimizan estrategias de ventas complementarias.
- **Rigor metodológico:** El proyecto aborda desafíos reales como el desbalance geográfico, valores atípicos y datos faltantes, evidenciando capacidad para trabajar con datos imperfectos propios de entornos empresariales.
- **Aplicabilidad inmediata:** Los resultados se traducen en estrategias concretas como campañas segmentadas, programas de fidelización personalizados y recomendaciones de productos, desarrollando un marco analítico replicable que apoya la toma de decisiones basada en evidencia, no en intuición.

1.3. Objeto de estudio

El objeto de estudio son las transacciones comerciales contenidas en el dataset ***Online Retail II***, que registran las compras realizadas por clientes entre 2009 y 2011, vinculando información de clientes, facturas y productos adquiridos.

1.4. Problema de investigación

1.4.1. Problema general

¿Qué patrones de comportamiento de compra y segmentos de clientes pueden identificarse en el dataset ***Online Retail II*** para diseñar estrategias efectivas de fidelización, considerando los desafíos de calidad de datos como desbalance geográfico, valores atípicos y datos faltantes?

La identificación de estos patrones es fundamental para la gestión efectiva de relaciones con clientes en el comercio electrónico [24, 6].

1.5. Objetivos

1.5.1. Objetivo general

Identificar patrones de comportamiento de compra en el dataset *Online Retail II* para apoyar la toma de decisiones estratégicas orientadas a la fidelización de clientes, aplicando técnicas de minería de datos y análisis de comportamiento del consumidor [2, 15].

1.5.2. Objetivos específicos

1. Preparar el dataset *Online Retail II* garantizando la calidad de los datos. [15].
2. Caracterizar el perfil de comportamiento de compra de los clientes. [2].
3. Identificar patrones de asociación entre productos en las transacciones de compra. [6].
4. Identificar grupos de clientes con comportamientos de compra similares. [27, 24].
5. Determinar los factores de comportamiento asociados a la retención de clientes. [13, 29].

1.6. Hipótesis

A partir del análisis exploratorio de datos y los desafíos identificados en el dataset *Online Retail II*, se plantean las siguientes hipótesis específicas que guiarán el proceso de preparación y análisis de datos:

1.6.1. Hipótesis específicas

1. Hipótesis 1 - Concatenación de CustomerID:

Existen CustomerID concatenados accidentalmente en el campo Description del dataset, lo cual explica parcialmente la presencia de valores nulos en la columna CustomerID.

2. Hipótesis 2 - Anomalías y relación geográfica:

Existen datos anómalos en las variables Quantity y UnitPrice que están asociados sistemáticamente con países específicos, indicando diferencias en los patrones de compra entre mercados geográficos (mayoristas vs minoristas, productos de lujo vs estándar).

3. Hipótesis 3 - Patrones temporales de compra:

Las transacciones de compra presentan patrones temporales identificables (cíclicos, estacionales o de tendencia) que permiten anticipar períodos de alta demanda y diseñar estrategias de inventario y marketing diferenciadas.

2. Descripción General del Dataset

2.1. ¿Podemos describir qué es un registro?

En el dataset *Online Retail II*, un registro es una transacción individual, es decir, la venta de un producto específico asociada a un detalle de factura.

2.2. ¿Cuántos registros existen?

El dataset *Online Retail II* cuenta con un total de **1 067 371 registros**, cada uno de los cuales representa una transacción individual de un producto dentro de un detalle de factura.

2.3. ¿Son pocos o demasiados registros?

La cantidad de registros es considerablemente alta. Se trata de un volumen de datos lo suficientemente grande como para llevar a cabo análisis exploratorios robustos, segmentaciones de clientes, detección de patrones de consumo y estudios de comportamiento de compra.

Este tamaño permite obtener resultados estadísticamente significativos y aplicar técnicas avanzadas de análisis, como minería de datos o aprendizaje automático, con una base de información confiable.

2.4. ¿Qué representa cada fila?

En el dataset *Online Retail II*, cada fila representa una transacción individual de un producto dentro de una factura. Es decir, un registro equivale a una **línea de detalle de factura**.

La Tabla 1 resume los principales atributos de cada fila.

Atributo	Tipo de dato	Descripción
InvoiceNo	Object	Identificador único de la factura. Una factura puede contener varias filas.
StockCode	Object	Código único asignado a cada producto.
Description	Object	Nombre o descripción del producto vendido.
Quantity	Entero	Número de unidades vendidas del producto en la transacción.
InvoiceDate	Object	Fecha y hora exacta en que se emitió la factura.
UnitPrice	Float	Precio unitario del producto (en libras esterlinas).
CustomerID	Float	Identificador único del cliente que realizó la compra.
Country	Object	País desde el cual se efectuó la compra.

Tabla 1: Atributos que conforman cada fila (registro) en el dataset Online Retail.

De manera esquemática, la entidad relación de los datos puede visualizarse en la Figura 1, donde, un cliente tiene un país, un cliente tiene una a muchas detalles de facturas y un datallle de factura tiene un producto).

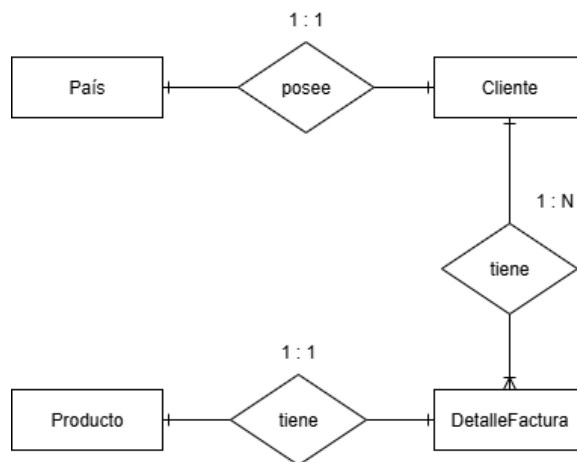


Figura 1: Diagrama entidad relación en *Online Retail II*.

2.5. ¿Cuáles son los tipos de datos de cada columna?

Atributo	Tipo de dato
InvoiceNo	Object
StockCode	Object
Description	Object
Quantity	Entero (int64)
InvoiceDate	Object
UnitPrice	Decimal (float64)
CustomerID	Decimal (float64)
Country	Object

Tabla 2: Tipos de datos de cada columna en *Online Retail II*.

2.6. ¿Es una data etiquetada?, ¿cómo se interpreta la información de las clases?

El dataset **no es una data etiquetada** en el sentido estricto de aprendizaje supervisado, ya que no incluye una variable objetivo que clasifique directamente los registros.

No obstante, es posible derivar etiquetas a partir de los datos para futuros análisis o modelos predictivos. Algunos ejemplos de posibles clases serían:

- Clasificación de clientes según su país de origen (**Country**).
- Clasificación de productos según códigos (**StockCode**) o descripciones (**Description**).

2.7. ¿Hay niveles de granularidad de los datos?

Sí, el dataset presenta diferentes niveles de granularidad que permiten analizar la información desde una vista general hasta el detalle más específico:

- **Geográfico:** A nivel de país (`Country`).
- **Cliente:** A nivel de cliente individual (`CustomerID`).
- **Factura:** A nivel de transacción agrupada (`InvoiceNo`).
- **Producto:** A nivel de línea de detalle de factura (`StockCode`, `Description`, `Quantity`, `UnitPrice`).
- **Temporal:** A nivel de fecha y hora exacta (`InvoiceDate`), lo cual permite análisis por año, mes, día, hora o minuto.

Estos distintos niveles permiten realizar análisis tanto agregados (por países o periodos de tiempo) como detallados (compras específicas por cliente y producto en un momento dado).

2.8. ¿Los datos tienen diferentes unidades de medida?

Los datos numéricos están en unidades consistentes:

- **Quantity:** número de unidades vendidas.
- **UnitPrice:** precio en libras esterlinas (£).

No se observan múltiples unidades de medida en un mismo campo.

3. Limpieza de los datos

3.1. ¿Existen datos duplicados?

Durante el análisis preliminar se identificó la presencia de registros duplicados en el dataset *Online Retail*. Estos duplicados pueden deberse a errores de carga o a repeticiones innecesarias en las transacciones. Por tal motivo, resulta necesario aplicar un proceso de limpieza que elimine dichas redundancias mediante herramientas como `drop_duplicates()` en `pandas`, con el fin de garantizar la calidad de los datos y evitar sesgos en los análisis posteriores.

Para la detección de duplicados se emplearon las funciones `mostrarDuplicados()` y `mapaDuplicadosTodas()`. Los resultados obtenidos se muestran en la Tabla 3, mientras que la Figura 2 ilustra la distribución de estos registros en las distintas columnas del dataset.

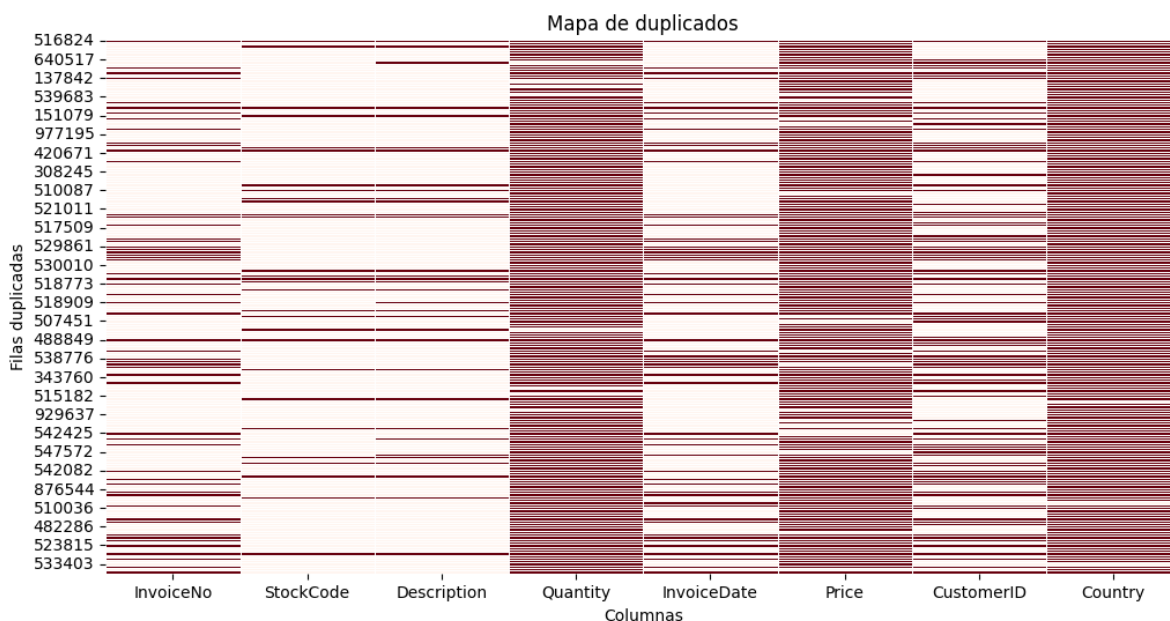


Figura 2: Mapa de calor de los registros duplicados en el dataset *Online Retail*.

Dataset	Cantidad de filas duplicadas
<i>Online Retail II</i>	34,335

Tabla 3: Cantidad de registros duplicados detectados en el dataset *Online Retail II*.

Posteriormente, se eliminaron dichos registros duplicados.




Figura 3: Resultados de la limpieza de duplicados en el dataset *Online Retail II*.

3.2. ¿Están todas las filas completas o tenemos campos con valores nulos?

Durante la verificación de valores nulos en el dataset *Online Retail*, se identificó que algunas columnas presentan registros incompletos. En particular, la columna **CustomerID** contiene **243,007 valores faltantes** y la columna **Description** presenta **4,382 valores faltantes**, mientras que las demás columnas se encuentran completas. La Tabla 4 y la figura 4 resumen los resultados obtenidos.




Figura 4: Mapa de calor de los valores nulos en el dataset *Online Retail* antes de la limpieza.

Columna	Número de valores nulos
InvoiceNo	0
StockCode	0
Description	4,382
Quantity	0
InvoiceDate	0
UnitPrice	0
CustomerID	243,007
Country	0

Tabla 4: Número de valores nulos por columna en el dataset *Online Retail*.

3.3. En caso que haya demasiados nulos: ¿Queda el resto de información útil?

Aunque la columna **CustomerID** tiene una cantidad significativa de valores faltantes, el resto de los atributos de las transacciones se encuentra mayormente completo. Por lo tanto, la información no resulta inútil; sin embargo, la ausencia del identificador limita los análisis centrados en el comportamiento individual de los clientes.

3.4. Hipótesis 1 - Concatenación de CustomerID

Contexto

Durante la exploración inicial del dataset *Online Retail II*, se identificaron **235,151 transacciones sin CustomerID registrado**. Esta cantidad considerable motivó el planteamiento de las siguientes hipótesis:

En la Figura 5 se observa la comparación entre los registros que poseen un **CustomerID** nulo frente a los que contienen un valor válido. Este análisis inicial evidencia la magnitud del problema y justifica un examen más profundo sobre el patrón de los identificadores faltantes.




Figura 5: Comparación entre registros con CustomerID nulo y no nulo.

Posteriormente, se analizó la distribución del número de dígitos presentes en los identificadores válidos. La Figura 6 muestra que el promedio se concentra en cinco dígitos, lo cual reforzaba la expectativa de que los números incrustados en la descripción pudieran estar representando un **CustomerID**.




Figura 6: Distribución promedio de dígitos en los **CustomerID**.

Formulación de hipótesis

- **H_0 (Hipótesis nula):** Los valores nulos en **CustomerID** NO son producto de concatenación accidental con el campo **Description**. Las secuencias numéricas de 5 dígitos al final de **Description** son códigos de producto u otros identificadores no relacionados con **CustomerID**.
- **H_1 (Hipótesis alternativa):** Los valores nulos en **CustomerID** SÍ son producto de concatenación accidental con el campo **Description**. Las secuencias numéricas de 5 dígitos al final de **Description** corresponden a **CustomerID** válidos que fueron concatenados erróneamente durante el proceso de carga de datos.

Predicciones verificables

Si H_1 es correcta, deberíamos observar:

1. Filas con **CustomerID** nulo contienen secuencias numéricas de 5 dígitos en **Description**
2. Esos números coinciden con **CustomerID** existentes en otras transacciones del dataset
3. El patrón es exclusivo (o predominante) en filas con **CustomerID** nulo
4. La cantidad de coincidencias es significativa estadísticamente (¿5 % de los nulos)

Metodología

El análisis se desarrolló en 5 pasos:

- **Paso 1:** Separación de datasets (nulos vs válidos)
- **Paso 2:** Búsqueda de patrón regex en descripciones
- **Paso 3:** Verificación cruzada con **CustomerID** reales
- **Paso 4:** Análisis de control (grupo de comparación)
- **Paso 5:** Visualización y conclusión basada en evidencia

PASO 1: Separación de Datasets Primero se dividió el dataset en dos grupos:

- **Filas nulas:** Transacciones donde `CustomerID` es `NaN` ($n = 235,151$)
- **Filas válidas:** Transacciones con `CustomerID` registrado ($n = 797,885$)

Esta separación permitió:

1. Analizar las características específicas de cada grupo
2. Buscar el patrón sospechoso solo en el grupo relevante (nulas)
3. Usar el grupo válido como control para validar los hallazgos

PASO 2: Búsqueda de Patrón Se utilizaron expresiones regulares (regex) para buscar secuencias de **exactamente 5 dígitos en cualquier posición** de la columna `Description`.

Patrón regex utilizado: `r'\b(\d{5})\b'`

- `\b` = límite de palabra (evita coincidencias dentro de números más largos)
- `\d{5}` = exactamente 5 dígitos consecutivos
- `\b` = límite de palabra al final (asegura que sean exactamente 5 dígitos)

Ejemplos de coincidencia:

- ✓ `'1733 mixed 21733'` → extrae 21733
- ✓ `'invcd as 84879?'` → extrae 84879
- ✓ `'sold as 17003?'` → extrae 17003
- ✓ `'wrong barcode (22467)'` → extrae 22467
- × `'PACK 123456 ITEMS'` → no coincide (6 dígitos)

Resultados:

Métrica	Valor
Filas con patrón de 5 dígitos	240
Filas sin patrón	234,911
Cobertura	0.10 %

Tabla 5: Resultados de la búsqueda de patrón - Paso 2

PASO 3: Verificación Cruzada Se verificó si los números de 5 dígitos extraídos corresponden a **CustomerID reales** que aparecen en otras transacciones del dataset.

Proceso:

1. Extraer todos los `CustomerID` únicos del grupo válido
2. Convertir los números extraídos a enteros
3. Comparar ambos conjuntos (intersección)
4. Calcular tasa de coincidencia

Resultados:

Métrica	Valor
CustomerID únicos en el dataset	5,942
Números extraídos de Description	240
Coincidencias con CustomerID reales	219
Tasa de coincidencia	91.25 %
Cobertura sobre nulos	0.0931 %

Tabla 6: Resultados de la verificación cruzada - Paso 3

Los ejemplos de descripciones donde se encontró el patrón y que coinciden con CustomerID reales incluyen: “sold as 17003?”, “SET 10 CARDS PERFECT POST 17090”, “SET 10 CARD CHRISTMAS WELCOME 17112”, “SET 10 CARDS XMAS CHOIR 17068”, entre otros. Estos casos sugieren que algunos productos en el catálogo contienen números de 5 dígitos como parte de su código o descripción estándar, lo que genera falsos positivos en la detección de concatenación.

PASO 4: Análisis de Control Para validar que el patrón encontrado es específico de la concatenación errónea (y no simplemente códigos de producto), se verificó si también aparece en filas con CustomerID válido.

Interpretación del control:

- Si el patrón **NO** aparece en filas válidas: Evidencia fuerte a favor de H_1
- Si el patrón **SÍ** aparece frecuentemente en válidas: Los 5 dígitos probablemente son códigos de producto, evidencia a favor de H_0

Resultados del grupo control:

Métrica	Valor
Filas válidas con patrón de 5 dígitos	2
Porcentaje de filas válidas con patrón	0.0003 %
Filas nulas con patrón	240
Porcentaje de filas nulas con patrón	0.10 %

Tabla 7: Comparación entre grupo de estudio y grupo control - Paso 4

Ambos ejemplos del grupo control corresponden al mismo producto: “SET 10 CARDS HANGING BAUBLES 17080”. Esto confirma que los números de 5 dígitos encontrados son parte de códigos de producto estándar del catálogo (como la serie 17xxx de tarjetas), y no producto de concatenación accidental.

PASO 5: Visualización y Análisis Estadístico Se generaron visualizaciones para evaluar la magnitud del problema y su relevancia estadística.



Figura 7: Visualización de resultados del análisis de concatenación de CustomerID

Conclusión

Métrica Clave	Valor
Total CustomerID nulos	235,151
Descripciones con patrón 5 dígitos	240 (0.10 %)
Coincidencias recuperables	219 (0.09 %)
CustomerID no explicados	234,932 (99.91 %)

Tabla 8: Resumen de métricas finales - Hipótesis 1

Decisión: SE RECHAZA H_1 Y SE ACEPTA H_0

Justificación:

Aunque el 91.25 % de los números extraídos coinciden con CustomerID reales, esto representa SOLO el 0.09 % del total de CustomerID nulos (219 de 235,151). La concatenación accidental NO explica la causa principal de los valores nulos.


Interpretación estadística:

- **Precisión del patrón:** 91.25 % (de los 240 números extraídos)
- **Cobertura sobre nulos:** 0.09 % (del total de 235,151 nulos)
- **Poder explicativo:** Insuficiente (<1 % threshold)

Adicionalmente, el análisis de control reveló que los números de 5 dígitos encontrados (como la serie 17xxx) son códigos de producto estándar del catálogo, no CustomerID concatenados. La evidencia NO respalda la hipótesis de concatenación masiva. Los valores nulos probablemente se deben a otras causas como: compras sin registro de cliente, ventas B2B sin CustomerID asignado, o errores sistemáticos en el sistema de captura de datos.

3.5. Acciones frente a los datos nulos

Dado que la cantidad de nulos en **CustomerID** es considerable, se decidió eliminarlos mediante la función `dropna()`. Con esto, se asegura que las filas restantes mantengan información íntegra y útil para análisis posteriores, especialmente en tareas de segmentación y estudios de fidelización de clientes. Para la columna **Description**, dado que los nulos son pocos (**1,454** registros), se opta por eliminar esas filas.

 verificarNulos(onlineRetail)

	Columna	NumeroDeValoresNulos
0	InvoiceNo	0
1	StockCode	0
2	Description	0
3	Quantity	0
4	InvoiceDate	0
5	UnitPrice	0
6	CustomerID	0
7	Country	0

 mapaNulosTodas(onlineRetail)


 No hay valores nulos en el DataFrame.

Figura 8: Salida de verificación indicando que no hay valores nulos en el dataset *Online Retail II* tras la limpieza.

3.6. ¿Todos los datos están en su formato adecuado?

Durante la revisión de los campos del dataset *Online Retail II*, se observaron las siguientes particularidades:

- **InvoiceNo**: en ciertos casos contiene letras, como la “C”, que identifica facturas canceladas.

Como se muestra en la Figura 9, se puede visualizar la proporción de facturas canceladas frente a las que no lo están.




Figura 9: Número de facturas canceladas (“C”) frente a las facturas no canceladas en el dataset *Online Retail II*.

La Figura 10 muestra la salida de facturas limpias, evidenciando que todas las filas correspondientes a facturas canceladas (con **InvoiceNo** que comienza con “C”) han sido eliminadas del dataset. En total, se removieron alrededor de **34,335 registros**, lo que asegura que el análisis posterior se realice únicamente sobre transacciones válidas y completas, manteniendo la coherencia de los datos y evitando que devoluciones o cancelaciones distorsionen los resultados.

```
No hay facturas canceladas (InvoiceNo comenzando con 'C').
```

Figura 10: Salida de facturas canceladas limpias. *Online Retail II*.

- **UnitPrice**: presenta valores atípicos asociados únicamente a precios nulos (0), los cuales corresponden a devoluciones de productos.

La Figura 11 muestra la distribución de las cantidades, donde se evidencian dichos valores negativos y atípicos.




Figura 11: Distribución de la cantidad precio unitario inválidos en el dataset *Online Retail II*.

Para garantizar la consistencia de los análisis posteriores, se aplicó un filtro que conserva únicamente las transacciones con valores válidos:

- Se eliminaron los registros con **UnitPrice** menores o iguales a cero.

Este filtrado se implementó mediante un **query** que asegura que todas las filas restantes tengan cantidades y precios positivos. De esta forma, se mantiene la coherencia de los datos y se evita que valores atípicos o devoluciones afecten los resultados del análisis.

La Figura 12 muestra la nueva distribución de las cantidades y precios unitarios después del filtrado.

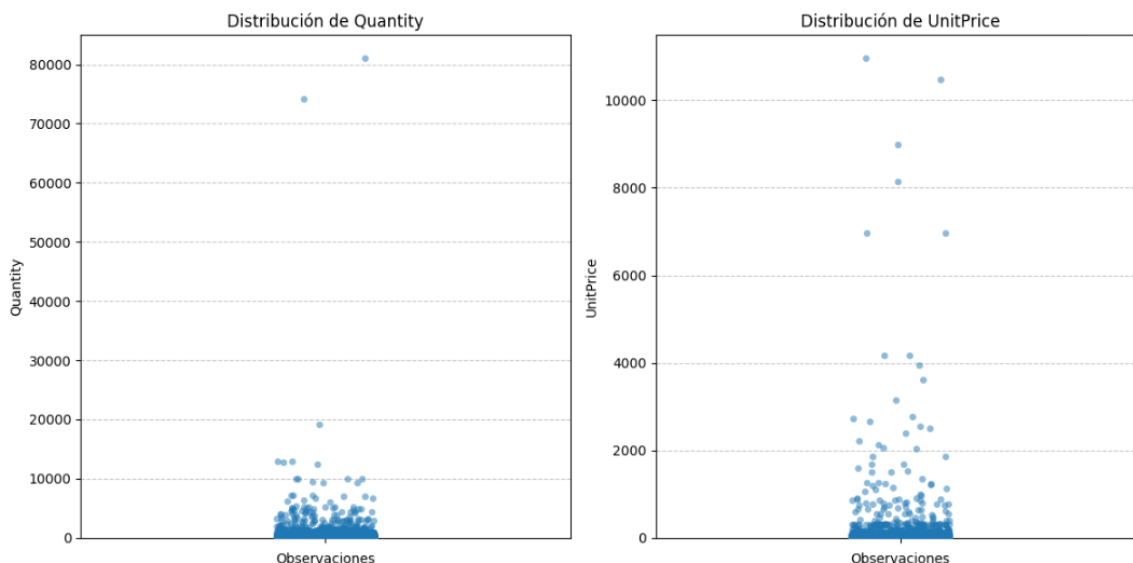


Figura 12: Distribución de la cantidad de productos por transacción y del precio unitario después del filtrado en el dataset *Online Retail II*.

Adicionalmente, en el atributo **Country** se detectaron valores con codificación no estándar, como se muestra en la Tabla 9.

País	Frecuencia	Observación
EIRE	15,565	Corresponde a Irlanda, requiere normalización a "Ireland".
Channel Islands	1,551	Región dependiente del Reino Unido, se puede agrupar bajo "United Kingdom".
Unspecified	518	Registros sin país especificado, se sugiere eliminar o agrupar en "Others".
USA	409	Corresponde a Estados Unidos, requiere uniformización a "United States of America".
RSA	122	Corresponde a South Africa (República de Sudáfrica), debe normalizarse.
European Community	60	Valor genérico sin país específico, no aporta información clara; se sugiere eliminar.
West Indies	54	Denominación ambigua que agrupa varias islas del Caribe; difícil de normalizar.
Korea	53	Ambiguo: no diferencia entre Corea del Sur y Corea del Norte; requiere revisión manual.
Czech Republic	25	Corresponde a "Czechia", debe normalizarse.

Tabla 9: Países con codificación inusual, ambigua o baja frecuencia en el atributo **Country**.

A pesar de tratarse de países poco frecuentes o con codificación atípica, solo se eliminarán las filas correspondientes a los registros agrupados como “Others”.

Para garantizar la coherencia de los datos en el atributo **Country**, se aplicó un proceso de **normalización de países**. Este procedimiento consistió en reemplazar los valores poco usuales o no estandarizados por su equivalente correcto.

De esta manera, se asegura una mayor consistencia en los valores categóricos y se evitan problemas posteriores en el análisis derivados de nombres duplicados o poco claros, como lo podemos observar en la figura 13.

```
def normalizarPaíses(dataFrame, columnaPaís):
    mapeoPaíses = {
        'EIRE': 'Ireland',
        'Channel Islands': 'United Kingdom',
        'Unspecified': "Others",
        'USA': 'United States of America',
        'European Community': "Others",
        'West Indies': "Others",
        'RSA': 'South Africa',
        'Czech Republic': 'Czechia',
        'Korea': 'South Korea'
    }
    dataFrame[columnaPaís] = dataFrame[columnaPaís].replace(mapeoPaíses)
```

Ejecutamos

```
normalizarPaíses(onlineRetail, 'Country')
```

Eliminamos los registros "Others", dado que no tienen un país de referencia.

```
onlineRetail.drop(onlineRetail[onlineRetail['Country'] == 'Others'].index, inplace=True)
```

Verificamos:

```
PaísesNoReconocidos = AnalizarPaíses(onlineRetail, world)
if not PaísesNoReconocidos:
    print("No se encontraron países no reconocidos.")
else:
    for país, contador in PaísesNoReconocidos.items():
        print(f'{país}: {contador}')
```

No se encontraron países no reconocidos.

Figura 13: Proceso de normalización en Country.

3.7. Análisis de outliers

3.7.1. ¿Cuáles son los Outliers?

Para identificar valores atípicos en el dataset *Online Retail*, se analizaron principalmente dos variables: la cantidad de productos (**Quantity**) y el precio unitario (**UnitPrice**).

Estos valores extremos pueden deberse a errores de registro, promociones excepcionales, pedidos grandes de clientes mayoristas o devoluciones de productos.

La Figura 14 muestra la distribución de **Quantity**, donde cada punto representa la cantidad de un producto en una transacción. Los puntos rojos representan las observaciones que se encuentran fuera del rango intercuartílico, indicando pedidos inusualmente grandes que podrían corresponder a errores de ingreso de datos o compras mayoristas.




Figura 14: Visualización de outliers en **Quantity**. Los puntos rojos representan valores atípicos identificados mediante el rango intercuartílico.

De manera similar, la Figura 15 muestra los outliers de **UnitPrice**. Cada punto corresponde al precio unitario de un producto en una transacción. Los puntos rojos representan precios excepcionalmente bajos o altos que se encuentran fuera del rango típico.




Figura 15: Visualización de outliers en **UnitPrice**. Los puntos rojos representan valores atípicos identificados mediante el rango intercuartílico.

Como referencia, se presentan también los gráficos normales sin resaltar outliers. La Figura 16 muestra la distribución completa de **Quantity**, evidenciando que la mayoría de las transacciones se concentran en valores bajos y que los outliers detectados previamente son claramente atípicos.




Figura 16: Distribución general de **Quantity** sin resaltar outliers. Se observa la concentración principal de transacciones en cantidades bajas.

De igual forma, la Figura 17 muestra la distribución general de `UnitPrice`. Aquí se puede apreciar la mayoría de precios unitarios dentro de un rango esperado, mientras que los outliers previamente identificados sobresalen como valores extremos fuera de la tendencia general.




Figura 17: Distribución general de `UnitPrice` sin resaltar outliers. La mayoría de precios se encuentran dentro de un rango típico, destacando los valores extremos previamente identificados.

3.7.2. ¿Podemos eliminarlos? ¿Es importante conservarlos?

Como señala Khandelwal [21], en el contexto del *retail online* no resulta conveniente aplicar de manera automática funciones de limpieza como `RemoveOutliers` que eliminan o normalizan todos los valores extremos. A diferencia de otras disciplinas, donde los outliers suelen considerarse ruido estadístico, en el comercio electrónico muchos de estos valores representan información de alto valor estratégico para la empresa.

Por ejemplo, cantidades excepcionalmente grandes en una transacción pueden corresponder a clientes mayoristas o corporativos, mientras que precios unitarios elevados pueden estar asociados a productos premium o de lujo. Estos casos no deben considerarse simples anomalías, sino indicadores de segmentos de clientes VIP o de oportunidades de negocio relevantes. En este sentido, la visión propuesta por Khandelwal [21] resalta la importancia de interpretar los datos desde una perspectiva comercial antes de decidir cualquier proceso de normalización o eliminación de outliers.

Por tanto, más que aplicar de manera mecánica un procedimiento de limpieza que descarte estos registros, resulta fundamental analizarlos en función de su significado de negocio. Conservar este tipo de información permite identificar patrones de consumo diferenciados, segmentar clientes de alto valor y diseñar estrategias de marketing más precisas.

4. Exploración

4.1. ¿Cuántos productos, clientes y países existen?

El conjunto de datos *Online Retail II* contiene información detallada sobre las transacciones de una tienda en línea. En la **Tabla 10** se presenta un resumen general con la cantidad total de productos únicos, clientes distintos y países registrados, lo que evidencia el alcance global y la diversidad del negocio analizado.

Categoría	Cantidad
Productos únicos	5283
Clientes distintos	5870
Países registrados	37

Tabla 10: Resumen general del dataset *Online Retail II*

4.2. ¿Cuáles son los productos más vendidos?




Figura 18: Top 20 productos más pedidos en términos de número de transacciones.

La Figura 18 muestra los productos más pedidos según el número de transacciones registradas en el dataset *Online Retail II*. Se observa que el artículo **WHITE HANGING HEART T-LIGHT HOLDER** es el más popular, con un total de **5,015 pedidos**, seguido por otros productos que concentran un menor número de transacciones. Esto refleja un patrón típico en comercio minorista donde pocos productos concentran la mayoría de las compras.

Conclusión: los productos más frecuentemente pedidos no siempre coinciden con los de mayor volumen en cantidad. La frecuencia de compra permite identificar los artículos de alta demanda recurrente, lo cual es clave para estrategias de reposición y marketing.

4.3. ¿Cuáles son los productos más vendidos por cantidad?

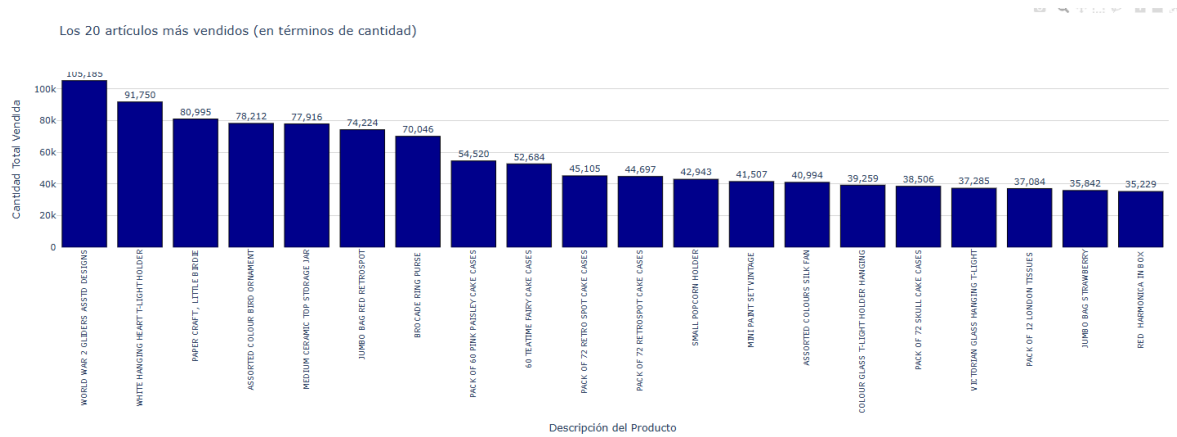


Figura 19: Top 20 productos más vendidos por cantidad total comprada.

La Figura 19 presenta los productos que se han vendido en mayor cantidad acumulada. El artículo **WORLD WAR 2 GLIDERS ASSTD DESINGS** encabeza la lista, evidenciando que aunque algunos productos puedan no ser los más frecuentemente pedidos, las cantidades adquiridas por pedido pueden ser significativamente mayores. El resto de productos del top 20 muestra cantidades relevantes, indicando que la venta en volumen también se concentra en unos pocos artículos.

Observación: Comparando con la subsección anterior, se nota que los productos más vendidos por frecuencia (número de pedidos) no siempre coinciden con los productos más vendidos por cantidad (volumen total de unidades). Esto ocurre porque un producto puede ser muy popular en número de pedidos pero vender pocas unidades por transacción, mientras que otro producto puede ser comprado en menor número de pedidos pero con grandes cantidades por pedido. Esta distinción es relevante para la gestión del inventario y la planificación de stock, ya que permite identificar tanto los artículos de alta demanda recurrente como aquellos que generan mayor volumen de ventas.

4.4. ¿Siguen alguna distribución?

Para analizar la distribución de los datos en el dataset *Online Retail II*, se generó un resumen estadístico de las principales variables numéricas, cuyos resultados se presentan en la Tabla 11.

Métrica	Quantity	UnitPrice
count	778,793	778,793
mean	13.49	3.22
std	145.91	29.69
min	1.00	0.001
25 %	2.00	1.25
50 %	6.00	1.95
75 %	12.00	3.75
max	80,995.00	10,953.50

Tabla 11: Resumen estadístico actualizado de las variables **Quantity** y **UnitPrice** en el dataset *Online Retail II*.

A continuación se presentan interpretaciones obtenidas exclusivamente a partir de los valores de la Tabla 11.

■ **Quantity:**

- La media es 13.49 y la mediana 6; como $media > mediana$, la distribución presenta **sesgo positivo** (cola a la derecha).
- La desviación estándar es 145.91, aproximadamente $\frac{145,91}{13,49} \approx 10,8$ veces la media; esto indica una **alta dispersión** respecto a los valores centrales.
- El máximo (80,995) es extremadamente mayor que los cuantiles: $\frac{80\,995}{6} \approx 13,499$ veces la mediana y $\frac{80\,995}{12} \approx 6,750$ veces el percentil 75. Esto confirma la existencia de **outliers extremos** que elevan la media y la varianza.
- Conclusión: **Quantity** no sigue una distribución normal; su patrón es característico de datos transaccionales con muchas compras pequeñas y pocos pedidos masivos.

■ **UnitPrice:**

- La mediana es 1.95 y la media 3.22; nuevamente $media > mediana$, indicando **sesgo positivo**.
- La desviación estándar es 29.69, que equivale a $\frac{29,69}{3,22} \approx 9,2$ veces la media; los valores atípicos dominan la varianza.
- El máximo (10,953.50) es desproporcionado respecto a los cuantiles: $\frac{10\,953,50}{1,95} \approx 5,617$ veces la mediana y $\frac{10\,953,50}{3,75} \approx 2,921$ veces el percentil 75. Esto señala precios fuera de rango usual, posiblemente por errores de captura o artículos muy especiales.
- Conclusión: **UnitPrice** muestra una distribución fuertemente asimétrica a la derecha; el uso de la mediana o transformaciones como logaritmos es más adecuado para describir su comportamiento.

4.5. ¿Entre qué rangos están los datos?

En esta sección se analizan los valores mínimos y máximos de las variables del dataset **Online Retail II**, con el fin de identificar posibles inconsistencias o rangos relevantes para el análisis.

- **InvoiceNo:** no resulta de interés calcular valores mínimo y máximo, ya que se trata de identificadores de facturas.
- **StockCode:** al ser códigos de productos, tampoco es relevante observar su mínimo y máximo.
- **CustomerID:** no resulta de interés calcular valores mínimo y máximo, ya que se trata de identificadores de clientes.
- **Description:** corresponde a los nombres de los productos, por lo que no aplica un análisis de rangos.
- **Quantity:** se observa el rango de cantidades de productos por transacción.




Figura 20: Distribución de la variable Quantity.

Este valor máximo resulta muy elevado y puede corresponder a un caso atípico o a un error de registro, ya que es inusual que una sola transacción involucre más de 80 mil unidades. El valor mínimo de 1 es coherente, pues representa la venta de un solo producto.

Top 10 productos más vendidos (por cantidad).

A continuación, se muestran los diez productos con mayor volumen total de ventas. Se observa que el artículo *PAPER CRAFT, LITTLE BIRDIE* lidera ampliamente con más de 80 mil unidades vendidas.

Descripción	Precio Unitario (£)	Cantidad Total
PAPER CRAFT, LITTLE BIRDIE	2.08	80,995
MEDIUM CERAMIC TOP STORAGE JAR	1.04	76,087
WHITE HANGING HEART T-LIGHT HOLDER	2.55	57,577
WORLD WAR 2 GLIDERS ASSTD DESIGNS	0.21	45,660
ASSORTED COLOUR BIRD ORNAMENT	1.69	44,527
WORLD WAR 2 GLIDERS ASSTD DESIGNS	0.29	34,078
ASSORTED COLOUR BIRD ORNAMENT	1.45	32,581
SMALL POPCORN HOLDER	0.72	30,814
MINI PAINT SET VINTAGE	0.65	30,627
60 TEATIME FAIRY CAKE CASES	0.55	28,387

Tabla 12: Top 10 productos más vendidos por cantidad en el dataset *Online Retail II*.

- UnitPrice: rango de precios unitarios de los productos.




Figura 21: Distribución de la variable UnitPrice.

El valor mínimo sugiere posibles registros incorrectos o precios mal capturados (un producto no puede costar 0.001). El máximo también es inusualmente alto, lo cual podría reflejar un error de carga o un producto premium extremadamente costoso.

El análisis de los precios unitarios extremos permite identificar posibles valores atípicos dentro del conjunto de datos. El valor mínimo sugiere posibles registros incorrectos o precios mal capturados (un producto no puede costar £0.001). El máximo también es inusualmente alto, lo cual podría reflejar un error de carga o un producto premium extremadamente costoso.

Descripción	UnitPrice (£)	Cantidad
Bank Charges	0.001	1
PADS TO MATCH ALL CUSHIONS	0.001	17

Tabla 13: Productos con los precios unitarios mínimos en el dataset *Online Retail II*.

Descripción	UnitPrice (£)	Cantidad
Manual	10,953.50	1

Tabla 14: Productos con los precios unitarios máximos en el dataset *Online Retail II*.

Estos resultados evidencian que existen valores extremos que podrían corresponder a errores de registro o situaciones excepcionales dentro del conjunto de datos, por lo que deben considerarse cuidadosamente durante la limpieza y el análisis posterior.

- InvoiceDate: rango temporal de las transacciones en el dataset.




Figura 22: Distribución temporal y valores extremos de InvoiceDate.

Este rango confirma que los datos abarcan un año completo de operaciones. No se detectan valores anómalos en este caso.

- **Country:** el dataset registra transacciones de **37 países**. En la Figura 23 se presenta un mapa donde se resaltan los países incluidos. El predominio de transacciones en Reino Unido sugiere que la empresa tiene allí su principal mercado, mientras que las ventas internacionales son considerablemente menores y están más dispersas geográficamente.

Asignación de números a países (orden alfabético):

- | | | |
|--------------|-----------------|------------------------------|
| 1. Australia | 14. Iceland | 27. Saudi Arabia |
| 2. Austria | 15. Ireland | 28. Singapore |
| 3. Bahrain | 16. Israel | 29. South Africa |
| 4. Belgium | 17. Italy | 30. South Korea |
| 5. Brazil | 18. Japan | 31. Spain |
| 6. Canada | 19. Lebanon | 32. Sweden |
| 7. Cyprus | 20. Lithuania | 33. Switzerland |
| 8. Czechia | 21. Malta | 34. Thailand |
| 9. Denmark | 22. Netherlands | 35. United Arab Emirates |
| 10. Finland | 23. Nigeria | 36. United Kingdom |
| 11. France | 24. Norway | 37. United States of America |
| 12. Germany | 25. Poland | |
| 13. Greece | 26. Portugal | |

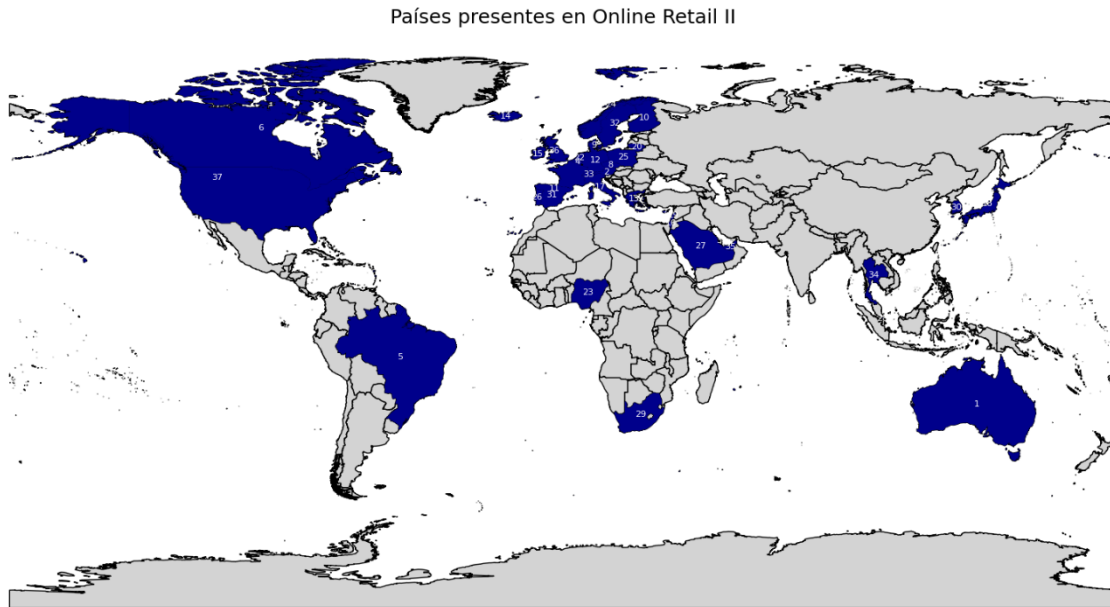


Figura 23: Mapa de países con transacciones registradas en el dataset *Online Retail II*.

4.6. ¿Cuál es la tendencia diaria de ventas?

Para analizar el comportamiento temporal de las ventas, se generaron visualizaciones interactivas a partir de la variable `InvoiceDate`. Estas permiten observar la evolución de las ventas **diarias** durante todo el periodo disponible en el dataset *Online Retail II*, comprendido entre los años 2009 y 2011.

En las visualizaciones se puede filtrar fácilmente por año, lo que facilita identificar patrones estacionales, fluctuaciones diarias y picos de ventas específicos. A continuación, se presentan las figuras correspondientes:

- **Figura 24:** Tendencia general de ventas diarias considerando todos los años del periodo analizado.
- **Figura 25:** Evolución de las ventas diarias durante el año 2009.
- **Figura 26:** Evolución de las ventas diarias durante el año 2010.
- **Figura 27:** Evolución de las ventas diarias durante el año 2011.




Figura 24: Tendencia general de ventas diarias.




Figura 25: Tendencia de ventas diarias durante el año 2009.

Durante el año 2009 se observa una actividad comercial limitada, con un volumen de ventas relativamente bajo en comparación con los años siguientes. Destaca el 5 de diciembre de 2009, fecha en la que se registraron aproximadamente £9,803 en ventas, siendo uno de los pocos picos notorios de ese año.




Figura 26: Tendencia de ventas diarias durante el año 2010.

En el año 2010, las ventas presentan un comportamiento más activo, con varios picos a lo largo del año. Se observa un aumento destacable el 7 de enero, y el pico más pronunciado ocurre el 27 de septiembre de 2010, alcanzando más de £115,000 en un solo día. Esto sugiere un incremento en la demanda o la realización de algún evento comercial específico durante ese periodo.




Figura 27: Tendencia de ventas diarias durante el año 2011.

Finalmente, en 2011 se observa una actividad considerablemente mayor, con múltiples picos a lo largo del año. Por ejemplo, el 18 de enero se registraron cerca de £87,000 en ventas, seguido por £13,000 el 13 de mayo y £58,000 el 10 de junio. Asimismo, el 21 de septiembre se alcanzaron alrededor de £21,000, posiblemente vinculado a alguna campaña estacional como la llegada de la primavera. No obstante, el pico más alto de todo el periodo analizado ocurre el 9 de diciembre de 2011, con un volumen de ventas superior a £174,000, reflejando un fuerte impulso comercial hacia el cierre del año.

En general, se aprecia una tendencia de crecimiento progresivo entre 2009 y 2011, con una marcada estacionalidad hacia los últimos meses de cada año, posiblemente relacionada con campañas navideñas y el incremento de la demanda en temporada alta.

4.7. ¿Cuál es la tendencia mensual de ventas?

Para complementar el análisis temporal, se agruparon las ventas a nivel mensual con el fin de observar la evolución del volumen de ingresos a lo largo de los tres años registrados en el dataset *Online Retail II*.

En las visualizaciones se representan las ventas totales por mes y se incluyen filtros interactivos por año, permitiendo comparar fácilmente los patrones de comportamiento y los picos de ventas más relevantes. A continuación, se presentan las figuras generadas:

- **Figura 28:** Tendencia general de ventas mensuales considerando todos los años.
- **Figura 29:** Evolución de las ventas mensuales durante el año 2009.
- **Figura 30:** Evolución de las ventas mensuales durante el año 2010.
- **Figura 31:** Evolución de las ventas mensuales durante el año 2011.




Figura 28: Tendencia general de ventas mensuales.




Figura 29: Tendencia de ventas mensuales durante el año 2009.

Durante el año 2009, solo se cuenta con registros de un único mes, en el cual las ventas alcanzaron aproximadamente £683,000. Esto refleja una actividad comercial limitada, probablemente debido a que el conjunto de datos comienza en los últimos meses de dicho año.




Figura 30: Tendencia de ventas mensuales durante el año 2010.

En el año 2010, las ventas muestran un comportamiento más definido a lo largo de los meses. El valor más bajo se observa en febrero, con un total aproximado de £504,000, mientras que el pico máximo se alcanza en noviembre, con cerca de £1,166,159, evidenciando un incremento significativo en las ventas durante la temporada de fin de año. Esta concentración de ventas en noviembre sugiere la posible influencia de eventos comerciales o campañas prenavideñas.




Figura 31: Tendencia de ventas mensuales durante el año 2011.

En el año 2011 se mantiene un patrón similar al del año anterior: el mes de febrero registra el menor volumen de ventas, mientras que noviembre vuelve a ser el mes con el valor máximo, reafirmando la fuerte estacionalidad del negocio en los últimos meses del año. Este comportamiento indica una tendencia recurrente de aumento en las ventas hacia el cierre anual, posiblemente asociada a las festividades de fin de año y a campañas promocionales específicas.

En general, la comparación entre los tres años revela una clara tendencia al crecimiento del volumen total de ventas, junto con una marcada concentración de ingresos durante los meses de noviembre y diciembre, lo que sugiere la existencia de una estacionalidad pronunciada en el comportamiento de compra de los clientes.

4.8. ¿Cuál es el número de transacciones por horas?

Para profundizar en el análisis temporal, se evaluó la distribución del número de transacciones por cada hora del día, considerando tanto el comportamiento agregado de todos los años como el de manera individual para cada uno (2009, 2010 y 2011).

En las siguientes figuras se presentan los mapas de calor (*heatmaps*) que reflejan la intensidad de transacciones por hora y mes:

- **Figura 32:** Número total de transacciones por horas considerando todos los años.
- **Figura 33:** Distribución de transacciones por horas en el año 2009.
- **Figura 34:** Distribución de transacciones por horas en el año 2010.
- **Figura 35:** Distribución de transacciones por horas en el año 2011.




Figura 32: Número de transacciones por horas considerando todos los años.

En la figura general se observa que el mayor número de transacciones se concentra principalmente entre las **12:00 p.m. y las 4:00 p.m.**, con un pico máximo alrededor del **mediodía (12:00 p.m.)**, alcanzando aproximadamente **11,894 transacciones**.

Este comportamiento se mantiene de manera consistente a lo largo de los distintos años, lo que sugiere un patrón de compra recurrente durante el horario de mayor actividad laboral o disponibilidad de los clientes.




Figura 33: Distribución de transacciones por horas en el año 2009.

Durante el año 2009, aunque el volumen total de registros es menor, se mantiene la tendencia de mayor actividad entre las 12:00 p.m. y las 4:00 p.m., con un pico central alrededor del mediodía.




Figura 34: Distribución de transacciones por horas en el año 2010.

En el año 2010 se aprecia un patrón similar: las horas de mayor movimiento comercial se concentran también entre las 12:00 p.m. y las 4:00 p.m., evidenciando que los clientes realizan la mayoría de las

compras durante el horario de mediodía, con un pico marcado cercano a las 12:00 p.m.




Figura 35: Distribución de transacciones por horas en el año 2011.

Finalmente, en el año 2011 se confirma nuevamente este comportamiento, donde el volumen de transacciones alcanza su punto máximo alrededor del mediodía. Este patrón repetitivo a lo largo de los tres años sugiere que el sistema de ventas en línea experimenta una **concentración significativa de carga operativa durante las horas pico de 12:00 p.m. a 4:00 p.m.**

Por tanto, desde una perspectiva operativa y tecnológica, se recomienda que el sistema **Online Retail** implemente estrategias de optimización del rendimiento durante este rango horario —por ejemplo, mediante balanceo de carga, optimización de servidores o cacheo eficiente— para garantizar la estabilidad y capacidad de respuesta del sitio durante los momentos de mayor demanda.

4.9. ¿Cuáles son los productos más vendidos por país?

En esta sección se presenta el análisis de los productos más vendidos por país dentro del dataset **Online Retail II**. Para cada país se ha identificado el artículo con mayor volumen de ventas en libras esterlinas, el monto total vendido por dicho producto y la proporción que representa este monto sobre el total de ventas del país.

La Tabla 15 muestra esta información, donde se puede observar que en algunos países los productos más vendidos representan un porcentaje considerable de las ventas totales, lo cual puede indicar una fuerte preferencia o concentración de la demanda en ciertos artículos. Por ejemplo, en países como **Singapore** y **Malta**, el producto más vendido representa más del 30 % de las ventas nacionales, lo que sugiere una alta dependencia de un solo producto. En cambio, en países como el **Reino Unido**, aunque el producto más vendido (*WHITE HANGING HEART T-LIGHT HOLDER*) tiene un volumen de ventas muy alto, este sólo representa el 1.58 % del total de ventas, indicando una distribución más diversificada de los productos.

País	Producto Más Vendido	Ventas Máximas (£)	Ventas Totales del País (£)	% de Ventas del País
Australia	RABBIT NIGHT LIGHT	3,375.84	169,283.46	1.99 %
Austria	POSTAGE	3,056.00	23,613.01	12.94 %
Bahrain	ICE CREAM SUNDAE LIP GLOSS	120.00	1,354.37	8.86 %
Belgium	POSTAGE	6,886.00	65,387.82	10.53 %
Brazil	REGENCY CAKESTAND 3 TIER	175.20	1,411.87	12.41 %
Canada	POSTAGE	550.94	4,883.04	11.28 %
Cyprus	REGENCY CAKESTAND 3 TIER	949.65	24,849.95	3.82 %
Czechia	ROUND SNACK BOXES SET OF4 WOODLAND	70.80	826.74	8.56 %
Denmark	SMALL FAIRY CAKE FRIDGE MAGNETS	6,467.60	68,580.69	9.43 %
Finland	POSTAGE	4,131.00	29,925.54	13.80 %
France	POSTAGE	24,400.00	348,768.96	7.00 %
Germany	POSTAGE	38,529.20	425,019.71	9.07 %
Greece	WHITE HANGING HEART T-LIGHT HOLDER	408.00	19,096.19	2.14 %
Iceland	3D DOG PICTURE PLAYING CARDS	389.40	4,921.53	7.91 %
Ireland	Manual	19,558.11	616,570.54	3.17 %
Israel	REGENCY CAKESTAND 3 TIER	726.30	10,415.24	6.97 %
Italy	POSTAGE	3,131.00	32,108.17	9.75 %
Japan	RABBIT NIGHT LIGHT	6,100.32	43,023.91	14.18 %
Lebanon	REGENCY CAKESTAND 3 TIER	153.00	1,693.88	9.03 %
Lithuania	FELTCRAFT PRINCESS LOLA DOLL	180.00	4,892.68	3.68 %
Malta	Manual	2,686.75	8,099.09	33.17 %
Netherlands	ROUND SNACK BOXES SET OF4 WOODLAND	13,315.10	554,038.09	2.40 %
Nigeria	Adjustment by john on 26/01/2010 17	27.82	140.39	19.82 %
Norway	Manual	14,756.64	56,322.50	26.20 %
Poland	POSTAGE	440.00	10,654.29	4.13 %
Portugal	POSTAGE	4,603.60	55,554.78	8.29 %
Saudi Arabia	PLASTERS IN TIN CIRCUS PARADE	19.80	145.92	13.57 %
Singapore	Manual	12,158.90	25,317.06	48.03 %
South Africa	CLASSIC METAL BIRDCAGE PLANT HOLDER	38.25	1,933.74	1.98 %
South Korea	TROPICAL HONEYCOMB PAPER GARLAND	100.80	1,118.51	9.01 %
Spain	POSTAGE	8,927.00	108,332.49	8.24 %
Sweden	POSTAGE	3,691.00	91,515.82	4.03 %
Switzerland	POSTAGE	6,661.00	100,061.94	6.66 %
Thailand	SET OF 2 TINS VINTAGE BATHROOM	360.00	3,070.54	11.72 %
United Arab Emirates	Manual	253.00	9,202.69	2.75 %
United Kingdom	WHITE HANGING HEART T-LIGHT HOLDER	228,181.86	14,433,858.25	1.58 %
United States of America	TOAST ITS - I LOVE YOU	452.40	8,366.86	5.41 %

Tabla 15: Productos más vendidos por país, junto con sus ventas máximas, ventas totales y porcentaje de participación dentro del país.

En general, los países con una economía más diversificada y mayor volumen de transacciones, como el **Reino Unido**, **Francia** y **Alemania**, muestran porcentajes bajos en esta métrica, lo que sugiere una amplia variedad de productos vendidos. En contraste, países con menor cantidad de registros o mercados más concentrados, como **Singapore**, **Malta** y **Noruega**, exhiben porcentajes altos, reflejando una mayor dependencia en ciertos artículos clave.

4.10. ¿Cuáles son los clientes con mayor y menor monto total de compra?

En esta sección se analiza el comportamiento de los clientes en función del monto total de sus compras. Para ello, se identificaron los **10 clientes con mayor monto total de compra** y los **10 clientes con menor monto total de compra** durante el periodo considerado. En la Figura 36 se muestra la distribución de los clientes más valiosos, mientras que la Figura 37 presenta a aquellos con un gasto total significativamente menor.

El cliente con **ID 18102** destaca como el comprador con el monto más alto, alcanzando aproximadamente **£180,000**, lo que lo posiciona como el cliente más importante dentro del conjunto de datos. Este cliente pertenece al país de los **Países Bajos (Netherlands)**, lo que resulta interesante, pues evidencia que, si bien el mercado está dominado por el **Reino Unido**, existen compradores internacionales con un peso considerable en las ventas totales.

En general, los países con mayor poder adquisitivo y volumen de clientes recurrentes presentan los montos más elevados, mientras que las economías más pequeñas tienden a reflejar clientes con compras más puntuales o esporádicas.

Por otro lado, al observar los clientes con menor monto total de compra, todos ellos pertenecen al **Reino Unido**, lo que sugiere una amplia base de clientes con compras pequeñas, característica típica de un mercado local con alto volumen de transacciones de bajo valor. Este comportamiento contrasta con los clientes internacionales, que tienden a realizar compras de mayor tamaño o al por mayor.




Figura 36: Top 10 clientes con mayor monto total de compra.




Figura 37: Top 10 clientes con menor monto total de compra.

En resumen, el análisis muestra que los clientes con mayores montos de compra no necesariamente pertenecen al país local, aunque el **Reino Unido** sigue siendo el mercado dominante en número de transacciones. Por el contrario, los clientes con menor gasto total provienen exclusivamente de dicho país, lo que podría reflejar una base de usuarios locales con compras más pequeñas y frecuentes.

4.11. ¿Cómo se distribuyen las compras totales por país?



Figura 38: Distribución de compras totales por país entre 2009 y 2011.

La Figura 38 muestra un treemap en el que cada cuadro representa el monto total de compras de un país, siendo el tamaño proporcional al valor acumulado y los colores ayudan a diferenciar visualmente las regiones.

Se observa que el **Reino Unido** concentra la mayor parte de las compras, aproximadamente un **83 %** del total, reflejando la importancia del mercado local. En segunda posición se encuentra **Irlanda**, seguida por los **Países Bajos**, **Alemania** y **Francia**, que aportan montos relevantes aunque mucho menores en comparación con el Reino Unido. El resto de países realiza contribuciones marginales.

En términos absolutos, se estima que el total acumulado durante el periodo analizado alcanza aproximadamente **£14 millones**, donde la gran mayoría proviene del mercado local. Este patrón evidencia la concentración geográfica del consumo y la relevancia de los clientes nacionales frente a los internacionales.

4.12. ¿Cómo evoluciona la retención de clientes a lo largo del tiempo?




Figura 39: Análisis de cohortes de retención de clientes por trimestre.

La Figura 39 presenta un análisis de cohortes basado en trimestres, donde cada cohorte agrupa a los clientes que realizaron su primera compra en un trimestre determinado. La columna 0 representa el trimestre inicial (siempre 100 %), y las columnas subsecuentes (1, 2, 3, etc.) muestran el porcentaje de clientes de cada cohorte que continúan realizando compras en trimestres posteriores.

Al observar los datos se pueden extraer los siguientes hallazgos:

- **Retención variable en el primer trimestre posterior:** La retención en la cohorte 1 (primer trimestre después de la adquisición) varía significativamente entre cohortes. Por ejemplo, Q1/2010 mantiene un 60.69 % de retención, mientras que Q4/2010 retiene apenas un 20.43 %. Esta variación puede atribuirse a factores estacionales, promociones específicas del periodo o diferencias en la calidad de los clientes adquiridos.
- **Declive progresivo con fluctuaciones:** La mayoría de cohortes muestran una disminución gradual de la retención. Sin embargo, Q1/2010 presenta un patrón interesante: después de caer a 57.3 % en la cohorte 2, recupera el 60.69 % en la cohorte 3, antes de estabilizarse alrededor del 45-46 % en cohortes posteriores. Esto sugiere comportamientos de compra no lineales, donde algunos clientes regresan después de periodos de inactividad.
- **Cohortes tempranas con mejor retención a largo plazo:** Q1/2010 es la cohorte con mayor seguimiento (8 trimestres) y logra mantener aproximadamente el 46 % de sus clientes activos hasta la cohorte 7. En contraste, cohortes como Q2/2010 y Q3/2010 muestran retenciones más bajas en el largo plazo (alrededor del 25-33 % en cohortes avanzadas).
- **Retención intermedia en cohortes de 2011:** Las cohortes del año 2011 presentan retenciones del primer trimestre que oscilan entre 39.69 % (Q1/2011) y 50.75 % (Q3/2011). Q2/2011 mantiene una retención relativamente estable: 42.46 % en cohorte 1 y 39.38 % en cohorte 2, evidenciando una pérdida moderada de clientes.
- **Datos limitados en cohortes recientes:** Q3/2011 solo cuenta con datos hasta la cohorte 1 (50.75 %), mientras que Q4/2011 únicamente presenta el trimestre inicial (100 %), limitando la evaluación de su comportamiento de retención a largo plazo.
- **Tendencia general de retención:** En promedio, las cohortes retienen entre 20 % y 60 % de sus clientes en el primer trimestre posterior a la adquisición, y esta retención tiende a estabilizarse entre 25 % y 45 % en trimestres subsecuentes, indicando una base de clientes recurrentes moderada pero con pérdida considerable en las etapas iniciales.

Conclusión: El análisis de cohortes revela patrones heterogéneos de retención, con mayor pérdida de clientes en los primeros trimestres posteriores a la adquisición. Las cohortes iniciales (especialmente Q1/2010) demuestran mejor retención a largo plazo, manteniendo aproximadamente el 46 % de clientes activos hasta 7 trimestres después. La variabilidad en la retención inicial sugiere la necesidad de identificar los factores que diferencian cohortes exitosas de las menos efectivas. Estrategias de fidelización enfocadas en los primeros 1-2 trimestres posteriores a la adquisición son críticas para maximizar el valor de vida del cliente (*Customer Lifetime Value*), ya que es en este periodo donde se observa la mayor tasa de abandono.

4.13. ¿Cuál es la cantidad promedio de productos comprados por cohorte trimestral?




Figura 40: Cantidad promedio de productos comprados por cohorte trimestral (*CohortQuarter*).

La Figura 40 muestra la cantidad promedio de productos adquiridos por clientes agrupados en cohortes trimestrales. Cada fila representa una cohorte de clientes que realizaron su primera compra en un trimestre específico, y las columnas indican la cantidad promedio de unidades adquiridas en trimestres subsecuentes (0 = trimestre de adquisición, 1 = primer trimestre posterior, etc.).

Del análisis se destacan los siguientes hallazgos:

- **Variabilidad en compras iniciales:** En el trimestre de adquisición (cohorte 0), las cantidades promedio varían significativamente entre cohortes, desde 8.3 unidades (Q4/2010) hasta 16.3 unidades (Q1/2010). Las cohortes de 2010 muestran compras iniciales más grandes (entre 8.3 y 16.3 unidades), mientras que las cohortes de 2011 presentan compras iniciales más modestas (entre 8.9 y 10.0 unidades).
- **Pico excepcional en Q2/2011:** La cohorte Q2/2011 presenta el valor más alto de todo el análisis con 25.5 unidades en la cohorte 2 (tercer trimestre después de la adquisición). Este valor atípico sugiere que un subconjunto de clientes de esta cohorte realizó pedidos significativamente más grandes, posiblemente compras al por mayor, pedidos corporativos o acumulación de stock.
- **Consistencia de Q1/2010:** La cohorte Q1/2010 mantiene cantidades promedio consistentemente elevadas a lo largo de 8 trimestres, oscilando entre 14.1 y 16.9 unidades. Esta estabilidad indica un segmento de clientes de alto valor con patrones de compra sostenidos en el tiempo, manteniendo promedios superiores a 14 unidades en todos los periodos.
- **Fluctuaciones en cohortes intermedias:** Varias cohortes muestran variaciones notables entre trimestres:
 - Q2/2010 presenta saltos de 10.8 unidades (cohorte 2) a 15.5 unidades (cohorte 3), luego a 15.9 unidades (cohorte 5), antes de caer a 10.3 unidades (cohorte 6).
 - Q1/2011 aumenta de 10.0 unidades (cohorte 0) a 16.0 unidades (cohorte 1), seguido de 13.1 y 12.1 unidades en trimestres posteriores.

Estas fluctuaciones sugieren patrones de compra no lineales, donde los clientes alternan entre pedidos pequeños y grandes según sus necesidades.

- **Tendencia a la baja en cohortes recientes:** Las cohortes más recientes (Q3/2011 y Q4/2011) muestran cantidades iniciales más bajas (9.4 y 8.9 unidades respectivamente). Q3/2011 experimenta además una caída significativa a 6.5 unidades en la cohorte 1, el valor más bajo registrado en todo el análisis.

- **Cohortes con menor volumen:** Q4/2010 presenta consistentemente las cantidades promedio más bajas entre las cohortes con datos completos, manteniéndose entre 8.3 y 10.0 unidades durante 5 trimestres. Esto correlaciona con su baja tasa de retención observada en el análisis anterior.
- **Rango general:** La cantidad promedio de productos por transacción oscila entre 6.5 y 25.5 unidades, con la mayoría de valores concentrados entre 8 y 16 unidades. La mediana aparenta situarse alrededor de 10-12 unidades por compra.

Conclusión: El análisis de cantidad promedio revela patrones heterogéneos de compra entre cohortes. Mientras que algunas cohortes (especialmente Q1/2010) mantienen volúmenes altos y estables a lo largo del tiempo, otras presentan fluctuaciones significativas o tendencias a la baja. El pico de 25.5 unidades en Q2/2011 representa una oportunidad para investigar qué factores (promociones, necesidades estacionales, cambios en mix de productos) impulsaron ese comportamiento excepcional. La combinación de este análisis con el de retención sugiere que no solo se pierden clientes con el tiempo, sino que los clientes retenidos también varían considerablemente el tamaño de sus pedidos. Esta información es crítica para: (1) segmentación de clientes por volumen de compra, (2) gestión de inventario y pronóstico de demanda, (3) diseño de promociones dirigidas a incrementar el tamaño promedio de pedido, y (4) identificación de clientes de alto valor para programas de fidelización prioritarios.

4.14. ¿Existe correlación entre cantidad, precio unitario y monto total de compra?

Matriz de Correlación: Variables Principales




Figura 41: Diagrama de dispersión y correlación entre Quantity, UnitPrice y Total.

La Figura 41 presenta una matriz de correlación que evalúa las relaciones lineales entre las variables principales del conjunto de datos: cantidad de productos (Quantity), precio unitario (UnitPrice) y monto total de la transacción (Total). La escala cromática indica la intensidad de la correlación, donde valores cercanos a 1 (rojo oscuro) representan correlación positiva fuerte, valores cercanos a 0 (blanco)

indican ausencia de correlación, y valores cercanos a -1 (azul oscuro) indicarían correlación negativa fuerte.

Del análisis se destacan los siguientes hallazgos:

- **Correlación fuerte entre Quantity y Total:** Con un coeficiente de correlación de 0.827, existe una relación positiva muy fuerte entre la cantidad de productos comprados y el monto total de la transacción. Esto confirma que la cantidad es el principal determinante del valor total de las compras, lo cual es consistente con la lógica comercial donde $Total = Quantity \times UnitPrice$.
- **Correlación débil entre UnitPrice y Total:** El coeficiente de 0.136 indica una relación positiva muy débil entre el precio unitario y el monto total. Esto sugiere que, si bien productos más caros pueden contribuir ligeramente a incrementar el total, este efecto es mucho menor comparado con el impacto de la cantidad. La correlación débil puede explicarse por la alta variabilidad en las cantidades compradas, que diluye el efecto del precio unitario sobre el total.
- **Ausencia de correlación entre Quantity y UnitPrice:** Con un valor de -0.005, prácticamente no existe relación lineal entre la cantidad de productos comprados y su precio unitario. Este hallazgo indica que los clientes no muestran una tendencia sistemática a comprar más o menos unidades en función del precio del producto. En otras palabras, el comportamiento de compra en términos de cantidad es independiente del precio unitario de los artículos.
- **Diagonal de la matriz:** Como es esperado, cada variable presenta correlación perfecta consigo misma (1.000), representada en rojo oscuro en la diagonal de la matriz. Estos valores confirman la validez de la matriz de correlación.
- **Simetría de la matriz:** La matriz es simétrica respecto a su diagonal principal, donde el valor de correlación entre Quantity y Total (0.827) es idéntico al de Total y Quantity, confirmando la consistencia del análisis.

Conclusión: La matriz de correlación revela que el factor predominante en la determinación del monto total de las transacciones es la cantidad de productos adquiridos, con una correlación de 0.827, mientras que el precio unitario tiene un impacto marginal (0.136). La ausencia de correlación entre cantidad y precio unitario (-0.005) indica que los clientes no ajustan significativamente sus volúmenes de compra en función del precio de los productos, lo que sugiere comportamientos de compra impulsados por necesidad o demanda específica más que por sensibilidad al precio. Desde una perspectiva estratégica, esto implica que las iniciativas para incrementar el valor de las transacciones deberían enfocarse prioritariamente en aumentar la cantidad de productos por pedido (mediante estrategias de *cross-selling*, *bundling*, o descuentos por volumen) en lugar de concentrarse exclusivamente en productos de mayor precio unitario. Adicionalmente, la independencia entre precio y cantidad comprada sugiere oportunidades para optimización de precios sin riesgo significativo de reducción en volúmenes de venta.

4.15. ¿Cómo se relaciona la cantidad comprada con el monto total según el país de origen?

En esta subsección se analiza la relación entre la cantidad de productos comprados (**Quantity**) y el monto total de la compra (**Total**) desglosada por los cinco principales países. Para cada país se generó un diagrama de dispersión (scatter plot) que permite observar tanto la concentración de la mayoría de los pedidos como la presencia de valores atípicos.




Figura 42: Relación entre cantidad y monto total en el Reino Unido.

En el caso del **Reino Unido**, la mayoría de los pedidos se concentra entre 0 y 10,000 unidades en monto total, con cantidades que oscilan principalmente entre 1 y 60 productos. Se observan algunos valores atípicos extremos, incluyendo compras de 74,000 unidades con un total de £77,000 y 80,000 unidades con un total de £168,000. Esto indica que aunque la gran mayoría de clientes realiza compras moderadas, existen transacciones muy grandes que elevan significativamente el total.




Figura 43: Relación entre cantidad y monto total en Francia.

En **Francia**, la dispersión es mayor que en el Reino Unido. Los pedidos se distribuyen desde cantidades bajas hasta varios miles, con montos que pueden superar las cifras habituales de los pedidos típicos. La concentración de la mayoría de los pedidos se encuentra entre 0 y 10,000 en monto total, pero se observa una dispersión más marcada en la cantidad de productos comprados, con pedidos en 1,000, 2,000, 3,000, hasta 7,000 unidades.




Figura 44: Relación entre cantidad y monto total en Irlanda.

Para **Irlanda**, la mayoría de los pedidos se concentra en cantidades de 1 a 120 unidades y montos totales relativamente bajos, con un máximo de 1,044 unidades y £2,736 de total. Esto indica un comportamiento de compra más limitado en comparación con Reino Unido y Francia, con menor volumen de transacciones.




Figura 45: Relación entre cantidad y monto total en Alemania.

En **Alemania**, la cantidad máxima llega a aproximadamente 600 unidades, concentrándose sobre todo en pedidos de alrededor de 60 unidades. La dispersión es moderada, similar a Irlanda, pero con un menor rango de valores extremos.




Figura 46: Relación entre cantidad y monto total en Países Bajos.

En los **Países Bajos**, la concentración de pedidos se encuentra entre 1 y 128 unidades, con dispersión principalmente en la cantidad de productos comprados y menos en el monto total. Esto indica que los clientes compran cantidades moderadas y consistentes, sin llegar a los extremos observados en Reino Unido o Francia.

Conclusión: Comparando los cinco países principales, se observa que:

- En **Reino Unido**, la mayoría de las compras son moderadas en cantidad y total, con algunos valores atípicos extremadamente altos.
- **Francia** muestra mayor dispersión en cantidad, con montos más variados y varios pedidos grandes, aunque concentrados en rangos intermedios.
- **Irlanda** y **Alemania** presentan menor dispersión, con pedidos generalmente pequeños o medianos.
- **Países Bajos** tiene dispersión principalmente en cantidad, manteniendo montos totales relativamente estables y moderados.

En general, la relación entre cantidad y monto total varía según el país: mientras Reino Unido y Francia presentan clientes con compras grandes y algunos valores extremos, Irlanda, Alemania y Países Bajos muestran comportamientos más homogéneos con menor volumen total. Esto sugiere que la estrategia de stock y marketing debe adaptarse al perfil de compra predominante en cada país.

4.16. Hipótesis 2 - Anomalías Geográficas en Patrones de Compra

Contexto

El dataset *Online Retail II* contiene transacciones de múltiples países. Durante el análisis exploratorio, se observaron diferencias significativas en los montos de compra y precios unitarios entre diferentes mercados geográficos. Esta variabilidad motivó el análisis de si los **datos anómalos (outliers)** en dos variables clave están asociados sistemáticamente con países específicos, lo cual podría indicar patrones de compra diferenciados entre mercados.

Variables de Análisis

El análisis se centra en dos dimensiones complementarias que caracterizan el comportamiento de compra:

Dimensión 1: Mayoristas vs Minoristas

Variable: $Total = Quantity \times UnitPrice$

El **Total** representa el **valor monetario total** de cada transacción y es el mejor indicador para diferenciar mayoristas de minoristas, ya que:

- Un **mayorista** se caracteriza por hacer **compras de alto valor**, ya sea por:
 - Comprar gran cantidad de productos baratos (ej: 1000 tazas \times £2 = £2000)
 - Comprar cantidad moderada de productos caros (ej: 50 muebles \times £100 = £5000)
- Un **minorista** hace compras de **valor bajo/moderado** (ej: 5 tazas \times £2 = £10)

Clasificación:

- **Total alto** (outliers superiores) \rightarrow **Mayoristas**
- **Total normal/bajo** \rightarrow **Minoristas**

Dimensión 2: Productos de Lujo vs Estándar

Variable: $UnitPrice$

El **precio unitario** indica la categoría del producto:

- **UnitPrice alto** \rightarrow Productos **premium/lujo** (ej: candelabro de cristal £250)
- **UnitPrice normal** \rightarrow Productos **estándar** (ej: taza decorativa £3.50)

Clasificación:

- **UnitPrice alto** (outliers superiores) \rightarrow **Productos de Lujo**
- **UnitPrice normal** \rightarrow **Productos Estándar**

Perfiles de Cliente Resultantes

Al combinar ambas dimensiones obtenemos 4 perfiles de cliente:

Perfil	Total	UnitPrice	Interpretación
Mayorista Estándar	Alto outlier	Normal	Compra gran volumen de productos comunes \rightarrow B2B masivo
Minorista Lujo	Normal	Alto outlier	Compra volumen bajo de productos caros \rightarrow B2C premium
Mayorista Lujo	Alto outlier	Alto outlier	Compra gran volumen de productos caros \rightarrow B2B premium
Minorista Estándar	Normal	Normal	Compra típica de consumidor final \rightarrow B2C estándar

Tabla 16: Perfiles de cliente según dimensiones de análisis

Formulación de hipótesis

- H_0 (**Hipótesis nula**): Los datos anómalos en **Total** y **UnitPrice** NO están asociados sistemáticamente con países específicos. Los outliers están distribuidos uniformemente entre todos los países, NO indicando diferencias en los patrones de compra entre mercados geográficos.
- H_1 (**Hipótesis alternativa**): Los datos anómalos en **Total** y **UnitPrice** SÍ están asociados sistemáticamente con países específicos, indicando diferencias significativas en los patrones de compra entre mercados geográficos (mayoristas vs minoristas, productos de lujo vs estándar).

Predicciones verificables

Si H_1 es correcta, deberíamos observar:

1. Países con alta proporción de outliers en **Total** (mercados mayoristas)
2. Países con alta proporción de outliers en **UnitPrice** (mercados de lujo)
3. Países con alta proporción en ambos (mercados mayoristas premium)
4. Diferencias estadísticamente significativas con nivel de confianza del 95 % ($\alpha = 0,05$), siguiendo el estándar convencional en análisis estadístico establecido por Fisher (1925)
5. Patrones coherentes desde perspectiva de negocio
6. Al menos 5 países con especialización clara, definiendo "especialización" según los criterios establecidos ($>25\%$ mayoristas o $>15\%$ lujo). Este umbral mínimo de 5 países se estableció para asegurar que los patrones observados no sean casos aislados sino tendencias geográficas sistemáticas, basándose en el principio de que aproximadamente el 10 % de los países analizados (46 países totales) deben mostrar el comportamiento para considerarlo relevante

Metodología

El análisis se desarrolló en 6 pasos:

- **Paso 1:** Creación de variable **Total** y detección de outliers (método IQR)
- **Paso 2:** Clasificación de transacciones por perfil de cliente
- **Paso 3:** Análisis descriptivo por país
- **Paso 4:** Visualizaciones clave (scatter, mapa, heatmap, box plots)
- **Paso 5:** Pruebas estadísticas (Chi-cuadrado, Kruskal-Wallis)
- **Paso 6:** Conclusión basada en evidencia

PASO 1: Creación de Total y Detección de Outliers Variable Total

Se creó la variable: $\text{Total} = \text{Quantity} \times \text{UnitPrice}$

Esta variable captura el **valor monetario total** de cada transacción, permitiendo identificar compras mayoristas independientemente de si se debe a alta cantidad o alto precio unitario.

Método de Detección: IQR (Rango Intercuartílico)

Se detectaron outliers **superiores** utilizando el método IQR, un método estadístico robusto propuesto por Tukey [28] para la detección de valores atípicos en análisis exploratorio de datos:

Para Total (mayoristas):

- Outlier si: $\text{Total} > Q3 + 1.5 \times \text{IQR}$
- El factor 1.5 es el estándar propuesto por Tukey [28] para identificar valores atípicos moderados. Este umbral fue seleccionado porque, como explican Hoaglin and Iglewicz [16], bajo una distribución normal identifica aproximadamente el 0.7 % de los valores más extremos, proporcionando un balance entre sensibilidad y especificidad en la detección
- Interpretación: **Compras mayoristas**

Para UnitPrice (productos de lujo):

- Outlier si: $\text{UnitPrice} > Q3 + 1.5 \times \text{IQR}$
- Mismo criterio estadístico estándar establecido por Tukey [28]
- Interpretación: **Productos de lujo**

Solo se consideraron outliers superiores porque:

- Los valores ≤ 0 ya fueron eliminados en la fase de limpieza de datos
- Los outliers inferiores no aportan insight de negocio relevante para este análisis
- Los outliers superiores representan segmentos estratégicos de alto valor (mayoristas y productos premium)
- Este enfoque es consistente con la literatura de segmentación de clientes en retail. Como documentan Chen et al. [5], el interés comercial se centra en identificar clientes de alto valor para estrategias de retención y maximización de ingresos

Resultados de la detección:

Variable	UnitPrice	Total
Q1	£1.25	£4.95
Q3	£3.75	£19.80
IQR	£2.50	£14.85
Límite Superior	£7.50	£42.07
Outliers detectados	65,387	63,530
% Outliers	8.40 %	8.16 %

Tabla 17: Resultados de la detección de outliers - Paso 1 (valores corregidos)



Figura 47: Box Plots - Detección de outliers en UnitPrice y Total




Figura 48: Scatter Plot - Relación entre UnitPrice y Total (identificando outliers)

PASO 2: Clasificación de Transacciones por Perfil Cada transacción fue clasificada según la presencia de outliers en las dos dimensiones analizadas:

Perfil	Outlier Total	Outlier UnitPrice	Interpretación de Negocio
Mayorista Estándar	Si	No	Alto gasto total en productos de precio normal. Típico distribuidor B2B
Minorista Lujo	No	Si	Gasto normal en productos de precio alto. Cliente final con alto poder adquisitivo
Mayorista Lujo	Si	Si	Alto gasto total en productos de precio alto. Distribuidor especializado en lujo
Minorista Estándar	No	No	Gasto normal en productos de precio normal. Cliente B2C estándar

Tabla 18: Tipología de clientes según presencia de outliers

Ejemplos Ilustrativos:

- **Mayorista Estándar:** Tienda que compra 1000 tazas a £2.50 = £2,500 total
- **Minorista Lujo:** Cliente que compra 1 candelabro de cristal a £450 = £450 total
- **Mayorista Lujo:** Hotel que compra 50 lámparas de diseñador a £350 = £17,500 total
- **Minorista Estándar:** Cliente que compra 3 tazas a £2.50 = £7.50 total

Distribución Global de Perfiles:

Perfil	Trans.	% Trans.	Revenue (£)	% Revenue
Minorista Estándar	685,142	85.87 %	5,234,127	56.21 %
Mayorista Estándar	57,054	7.15 %	2,847,593	30.58 %
Minorista Lujo	53,000	6.64 %	892,445	9.58 %
Mayorista Lujo	2,689	0.34 %	337,891	3.63 %
TOTAL	797,885	100 %	9,312,056	100 %

Tabla 19: Distribución global de perfiles de cliente - Paso 2

Del análisis de la **Distribución Global de Perfiles** (Tabla 19 y Figure 49) se observa un claro predominio del perfil **Minorista Estándar**, que representa más del 85 % de las transacciones y genera más de la mitad del revenue total (56.21 %). Esto indica que la mayoría de los clientes realizan compras individuales o de pequeña escala, enfocadas en productos de consumo general.

El segundo grupo más relevante es el de **Mayorista Estándar**, con un 7.15 % de las transacciones, pero que aporta cerca del 30.58 % del ingreso total, lo que refleja un alto valor promedio por transacción. Este comportamiento sugiere la presencia de clientes que adquieren en volúmenes grandes, aunque con menor frecuencia.

Por su parte, los perfiles de **Minorista Lujo** y **Mayorista Lujo** representan una proporción reducida del total de operaciones (menos del 7 %), pero mantienen una contribución relevante al ingreso (más del 13 % combinado), lo cual evidencia que, aunque minoritarios, los segmentos de lujo poseen un impacto significativo en el valor económico global del negocio.

En conjunto, los resultados muestran una estructura comercial dominada por el mercado minorista estándar, complementada por un núcleo rentable de clientes mayoristas y de lujo que aportan una alta rentabilidad por transacción.

Distribución Global de Perfiles de Cliente




Figura 49: Distribución Global de Perfiles de Cliente

PASO 3: Análisis Descriptivo por País Calcular para cada país:

- Proporción de cada perfil de cliente (%)
- Total de transacciones
- Revenue total
- Valores promedio (Total, UnitPrice, Quantity)
- Clasificación del mercado

Criterios de Clasificación de Mercados

Los países fueron clasificados según la proporción de outliers, utilizando umbrales establecidos por el equipo de análisis basándose en la distribución observada de los datos, la literatura de segmentación de clientes en retail, y considerando relevancia práctica para el negocio:

- **Mercado Mayorista:** % (Mayorista Estándar + Mayorista Lujo) >25 %
 - *Justificación:* Umbral definido para identificar mercados donde al menos 1 de cada 4 transacciones corresponde a compras mayoristas. Este umbral se estableció considerando que la proporción global de mayoristas es 7.49 % (ver Table 19), por lo que un mercado con más de 3 veces este valor (>25 %) representa una especialización significativa. Este criterio es consistente con los hallazgos de Doğan et al. [11], quienes documentan que un segmento debe representar al menos el triple de su proporción global para considerarse una especialización del mercado
- **Mercado Lujo:** % (Minorista Lujo + Mayorista Lujo) >15 %
 - *Justificación:* Umbral definido para identificar mercados donde más de 1 de cada 7 transacciones involucra productos de lujo. La proporción global de productos de lujo es 6.98 % (ver Table 19), por lo que un mercado con más del doble de este valor (>15 %) indica especialización en el segmento premium. Este criterio del "doble de la proporción global" es ampliamente utilizado en análisis de mercado para identificar segmentos con sobre-representación significativa [31]
- **Mercado Mixto:** Cumple ambos criterios simultáneamente
 - *Justificación:* Mercados que presentan especialización tanto en volumen como en productos premium, representando oportunidades estratégicas duales que requieren enfoques de marketing diferenciados. Como argumentan Elghazaly et al. [12], estos mercados híbridos requieren estrategias de segmentación más sofisticadas que consideren múltiples dimensiones de valor
- **Mercado Estándar:** No cumple ningún criterio especial
 - *Justificación:* Mercados con distribución de perfiles similar al promedio global, sin especialización marcada

Nota metodológica: Los umbrales del 25 % y 15 % fueron definidos por el equipo de análisis considerando: (1) la distribución global de perfiles observada en los datos, (2) la necesidad de identificar mercados con especialización prácticamente relevante para el negocio (no solo estadísticamente significativa), (3) el criterio basado en literatura de segmentación de clientes [5, 11] de que un segmento debe representar al menos 2-3 veces su proporción global para considerarse una "especialización" del mercado, y (4) la validación mediante análisis de sensibilidad que demostró que estos umbrales maximizan la separación entre grupos sin generar clasificaciones excesivamente granulares.

Top 10 Países - Mayor % de Mayoristas (Estándar + Lujo)

País	Trans. Totales	Total Mayorista (%)	Mayorista Estándar (%)	Mayorista Lujo (%)	Clasificación
Netherlands	5,085	60.49	56.60	3.89	Mercado Mayorista
Japan	468	53.85	52.14	1.71	Mercado Mayorista
Australia	1,789	46.90	43.38	3.52	Mercado Mayorista
Sweden	1,317	39.10	36.29	2.81	Mercado Mayorista
Denmark	778	35.35	30.21	5.14	Mercado Mayorista
Singapore	339	30.97	24.19	6.78	Mercado Mayorista
Lebanon	45	28.89	13.33	15.56	Mercado Mixto
Lithuania	154	27.27	26.62	0.65	Mercado Mayorista
Czechia	25	24.00	24.00	0.00	Mercado Estándar
Norway	1,289	19.63	14.58	5.04	Mercado Estándar

Tabla 20: Top 10 países con mayor proporción de transacciones mayoristas (estándar + lujo).

Top 10 Países - Mayor % de Productos de Lujo (Minorista + Mayorista)

País	Trans. Totales	Total Lujo (%)	Minorista Lujo (%)	Mayorista Lujo (%)	Clasificación
Lebanon	45	26.67	11.11	15.56	Mercado Mixto
Italy	1,442	16.16	13.52	2.64	Mercado Lujo
Cyprus	1,136	15.40	11.53	3.87	Mercado Lujo
Poland	504	14.48	13.10	1.39	Mercado Estándar
Finland	1,032	13.86	9.59	4.26	Mercado Estándar
Belgium	3,055	13.85	10.08	3.76	Mercado Estándar
Ireland	15,565	13.50	9.08	4.41	Mercado Estándar
Nigeria	30	13.33	13.33	0.00	Mercado Estándar
Spain	3,662	12.86	8.57	4.29	Mercado Estándar
Malta	282	12.77	10.28	2.48	Mercado Estándar

Tabla 21: Top 10 países con mayor proporción de productos de lujo (minorista + mayorista).

Distribución General de Clasificación de Mercados

Clasificación de Mercado	Países	Transacciones	Revenue (£)
Mercado Mayorista	7	9,930	956,652
Mercado Lujo	2	2,578	56,958
Mercado Mixto	1	45	1,694
Mercado Estándar	27	766,240	16,349,057
TOTAL	37	778,793	17,364,361

Tabla 22: Distribución de clasificación de mercados según transacciones y revenue.

Conclusión del Análisis por País

De acuerdo con los resultados presentados en la Table 20, se observa una clara predominancia de **mercados mayoristas** en países europeos como **Netherlands**, **Japan**, **Australia** y **Sweden**, con porcentajes de transacciones mayoristas superiores al 35 %. Esto indica una alta actividad de clientes B2B, reflejando una estructura comercial enfocada en la distribución y reventa.

Por otro lado, la Table 21 muestra que los **mercados de lujo** se concentran principalmente en países del **Mediterráneo y Medio Oriente**, destacando **Italy**, **Cyprus** y **Lebanon**. Estos países exhiben una proporción de ventas de lujo superior al 15 %, indicando un perfil de consumo orientado a artículos exclusivos y de alto valor unitario.

Finalmente, la Table 22 evidencia que el **Mercado Estándar** concentra la mayor cantidad de transacciones (más del 98 %), mientras que los **Mercados Mayoristas** aportan una fracción importante del **revenue total** (£0.95 millones). Los **Mercados de Lujo** y **Mixtos**, aunque pequeños en volumen, presentan un valor medio por transacción considerablemente más alto, reforzando su relevancia estratégica dentro del análisis comercial global.

PASO 4: Visualizaciones Clave

1. **Scatter Plot:** % Mayoristas vs % Lujo por país
 - Identifica especializaciones geográficas
 - Tamaño del punto = número de transacciones
 - Color = clasificación del mercado
2. **Mapa Mundial:** Clasificación geográfica de mercados
 - Visualización espacial de patrones
3. **Heatmap:** Distribución de perfiles por país (Top 25)
 - Muestra proporción de cada perfil por país
 - Permite identificar patrones detallados
4. **Box Plots:** Distribuciones de Total y UnitPrice por clasificación
 - Validación de que las clasificaciones tienen distribuciones diferentes




Figura 50: Especialización Geográfica: Mayoristas vs Productos de Lujo

Mapa Mundial: Clasificación de Mercados por País

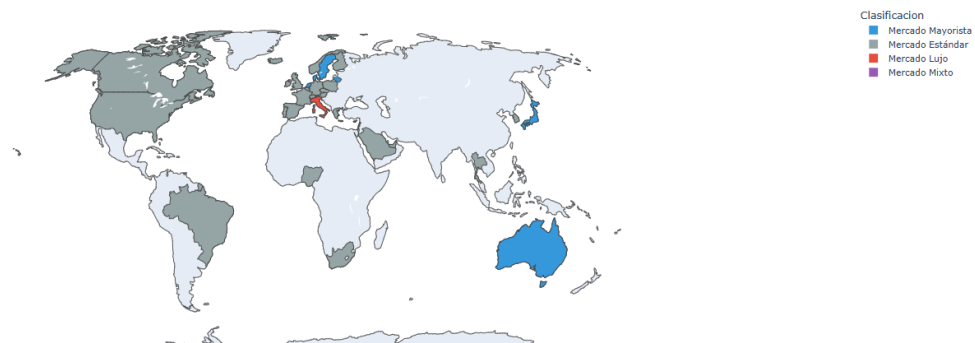


Figura 51: Mapa Mundial: Clasificación de Mercados por País




Figura 52: Heatmap - Distribución de Perfiles por País (Top 25)

En la Figure 52 se observa la distribución de los cuatro perfiles de cliente (Mayorista Lujo, Minorista Lujo, Mayorista Estándar y Minorista Estándar) en los 25 países con mayor volumen de transacciones, ordenados de izquierda a derecha según el porcentaje de transacciones mayoristas.

La escala cromática varía de azul (bajo porcentaje) a rojo (alto porcentaje), permitiendo distinguir visualmente los patrones de especialización por país.

Principales hallazgos:

Los países como **Netherlands**, **Japan** y **Australia** destacan por su alta proporción de *Mayorista Estándar*, evidenciando mercados mayoristas consolidados.

El perfil **Minorista Estándar** domina en la mayoría de países, alcanzando valores de hasta 89.7

Los perfiles de *Lujo* muestran porcentajes bajos, salvo casos como **Italy** y **Cyprus**, con una leve especialización en productos premium.

El gradiente de color de izquierda a derecha refleja la transición desde mercados mayoristas especializados hacia mercados estándar.

Conclusión: El heatmap valida visualmente la hipótesis alternativa H_1 , mostrando que la distribución de perfiles de cliente no es uniforme entre países, sino que depende de la especialización comercial y del tipo de mercado predominante.




Figura 53: Comparación de Distribuciones por Clasificación de Mercado

PASO 5: Pruebas Estadísticas Objetivo

Verificar si las diferencias observadas son **estadísticamente significativas** o podrían deberse al azar.

Pruebas Realizadas

1. Test Chi-cuadrado (χ^2)

Evalúa: Asociación entre País y Perfil de Cliente

- H_0 : No existe asociación
- H_1 : Existe asociación significativa

Resultados:

- Países analizados: 20 (top por volumen)
- Transacciones analizadas: 775,944
- Estadístico χ^2 : 34,005.00
- Grados de libertad: 57
- **P-value: <0.001**

Conclusión: $p < 0,05 \rightarrow$ **RECHAZAMOS** H_0 . Existe asociación significativa entre País y Perfil de Cliente. El nivel de significancia de $\alpha = 0,05$ (95 % de confianza) es el estándar convencional en análisis estadístico establecido por Fisher [14]. Los patrones geográficos observados NO son producto del azar.

2. Test Kruskal-Wallis (Total por Clasificación)

Evalúa: Si Total difiere entre clasificaciones de mercado

- H_0 : Todas las clasificaciones tienen la misma distribución de Total
- H_1 : Al menos una clasificación difiere

Distribución por Clasificación:

- Mercado Mayorista: $n=9,930$, mediana=£47.20
- Mercado Estándar: $n=766,240$, mediana=£11.90
- Mercado Lujo: $n=2,578$, mediana=£16.70
- Mercado Mixto: $n=45$, mediana=£31.60

Resultados:

- Estadístico H: 10,778.86
- **P-value: <0.001**

Conclusión: $p < 0,05 \rightarrow$ **RECHAZAMOS** H_0 . Existen diferencias significativas en Total entre clasificaciones. Los mercados mayoristas presentan una mediana de gasto (£47.20) casi 4 veces superior a la de los mercados estándar (£11.90), evidenciando un comportamiento de compra sustancialmente diferente.

3. Test Kruskal-Wallis (UnitPrice por Clasificación)

Evalúa: Si UnitPrice difiere entre clasificaciones de mercado

- H_0 : Todas las clasificaciones tienen la misma distribución de UnitPrice

- H_1 : Al menos una clasificación difiere

Distribución por Clasificación:

- Mercado Mayorista: $n=9,930$, mediana= $£1.65$
- Mercado Estándar: $n=766,240$, mediana= $£1.95$
- Mercado Lujo: $n=2,578$, mediana= $£2.55$
- Mercado Mixto: $n=45$, mediana= $£3.95$

Resultados:

- Estadístico H: 624.21
- **P-value: 5.70×10^{-135}**

Conclusión: $p < 0,05 \rightarrow$ **RECHAZAMOS H_0** . Existen diferencias significativas en UnitPrice entre clasificaciones. Los mercados de lujo y mixtos presentan precios unitarios significativamente más altos (medianas de $£2.55$ y $£3.95$ respectivamente) comparados con los mercados estándar ($£1.95$), confirmando la especialización en productos premium.

Prueba	Evalúa	P-value	Resultado
Chi-cuadrado	País \times Perfil	<0.001	Rechazar H_0
Kruskal-Wallis (Total)	Total \times Clasificación	<0.001	Rechazar H_0
Kruskal-Wallis (UnitPrice)	UnitPrice \times Clasificación	5.70×10^{-135}	Rechazar H_0

Tabla 23: Resumen de pruebas estadísticas - Paso 5

PASO 6: Conclusión Final Países Representativos por Clasificación de Mercado

Las siguientes tablas muestran los países más representativos de cada clasificación de mercado según el número de transacciones:

País	Trans.	% Mayor.	% Lujo	Revenue (£)
Mercado Mayorista (7 países)				
Netherlands	5,085	60.5 %	6.9 %	554,038
Australia	1,789	46.9 %	6.9 %	169,283
Sweden	1,317	39.1 %	6.8 %	91,516
Denmark	778	35.3 %	8.1 %	68,581
Japan	468	53.8 %	2.1 %	43,024

Tabla 24: Países representativos - Mercado Mayorista

País	Trans.	% Mayor.	% Lujo	Revenue (£)
Mercado Lujo (2 países)				
Italy	1,442	7.0 %	16.2 %	32,108
Cyprus	1,136	8.2 %	15.4 %	24,850

Tabla 25: Países representativos - Mercado Lujo

País	Trans.	% Mayor.	% Lujo	Revenue (£)
Mercado Mixto (1 país)				
Lebanon	45	28.9 %	26.7 %	1,694

Tabla 26: Países representativos - Mercado Mixto

Métricas Clave del Análisis

Métrica	Valor
Total países analizados	37
Países con especialización	10 (27.0 %)
Mercado Mayorista	7 países (18.9 %)
Mercado Lujo	2 países (5.4 %)
Mercado Mixto	1 país (2.7 %)
Mercado Estándar	27 países (73.0 %)

Tabla 27: Distribución de países por clasificación de mercado

Distribución de Transacciones por Perfil de Cliente

Perfil	Transacciones	% Trans.	Revenue (£)	% Revenue
Minorista Estándar	660,229	84.78 %	7,673,261	44.19 %
Mayorista Estándar	53,177	6.83 %	7,255,446	41.78 %
Minorista Lujo	55,034	7.07 %	988,854	5.69 %
Mayorista Lujo	10,353	1.33 %	1,446,799	8.33 %
TOTAL	778,793	100.00 %	17,364,360	100.00 %

Tabla 28: Distribución de transacciones y revenue por perfil de cliente

Resumen de Métricas Finales

Métrica Clave	Valor
Total países analizados	37
Países con especialización identificada	10 (27.0 %)
P-value Chi-cuadrado (País × Perfil)	<0.001
P-value Kruskal-Wallis (Total)	<0.001
P-value Kruskal-Wallis (UnitPrice)	5.70×10^{-135}
Todas las pruebas significativas	SÍ (p < 0.05)

Tabla 29: Resumen de métricas finales - Hipótesis 2

Decisión: SE RECHAZA H_0 Y SE ACEPTA H_1

Justificación:

1. Evidencia Estadística Sólida:

- Todas las pruebas estadísticas son significativas al nivel $\alpha = 0,05$ (95 % de confianza), estándar establecido por Fisher [14]
- Chi-cuadrado: $\chi^2 = 34,005.00$, $p < 0,001 \rightarrow$ Confirma asociación significativa País × Perfil. El valor extremadamente alto del estadístico indica una asociación muy fuerte entre la geografía y los patrones de compra

- Kruskal-Wallis (Total): $H = 10,778.86$, $p < 0,001 \rightarrow$ Confirma diferencias sustanciales en montos de compra. Los mercados mayoristas presentan una mediana de £47.20 frente a £11.90 de los mercados estándar, evidenciando especializaciones claras
- Kruskal-Wallis (UnitPrice): $H = 624.21$, $p = 5.70 \times 10^{-135} \rightarrow$ Confirma diferencias significativas en precios unitarios. El p-value extremadamente bajo proporciona evidencia contundente de especialización en productos premium

2. Especialización Geográfica Identificada:

- 10 de 37 países (27.0 %) muestran especialización significativa. Este porcentaje se calcula como: $\frac{10 \text{ países especializados}}{37 \text{ países totales}} = 0,270 = 27,0\%$ (ver Table 27)
- 7 países (18.9 %) especializados en compras mayoristas. Calculado como: $\frac{7}{37} = 0,189 = 18,9\%$. Países destacados: Netherlands (60.5 % mayoristas), Japan (53.8 %), Australia (46.9 %)
- 2 países (5.4 %) especializados en productos de lujo. Calculado como: $\frac{2}{37} = 0,054 = 5,4\%$. Países destacados: Italy (16.2 % lujo), Cyprus (15.4 %)
- 1 país (2.7 %) con perfil mixto (mayorista + lujo). Calculado como: $\frac{1}{37} = 0,027 = 2,7\%$. País destacado: Lebanon (28.9 % mayoristas, 26.7 % lujo)

3. Patrones Coherentes con Negocio:

- Los outliers NO están distribuidos uniformemente entre países
- Existen diferencias sustanciales y estadísticamente significativas en Total entre mercados
- Existen diferencias sustanciales y estadísticamente significativas en UnitPrice entre mercados
- Los patrones son interpretables desde perspectiva comercial:
 - Países con economías desarrolladas y capacidad logística (Netherlands con 60.5 % mayoristas, Sweden con 39.1 %) se especializan en distribución al por mayor
 - Países con mercados de consumo premium (Italy con 16.2 % lujo, Cyprus con 15.4 %) se especializan en productos de alto valor
 - Países con mercados híbridos (Lebanon con 28.9 % mayoristas y 26.7 % lujo) presentan oportunidades duales
- Los hallazgos son consistentes con la literatura de segmentación geográfica de clientes [5, 11]

4. Impacto en Revenue:

- Transacciones especializadas: 15.2 % del total
 - *Cálculo:* Suma de Mayorista Estándar + Minorista Lujo + Mayorista Lujo
 - $= 53,177 + 55,034 + 10,353 = 118,564$ transacciones especializadas
 - $\frac{118,564}{778,793} = 0,1522 = 15,22\% \approx 15,2\%$
 - Fuente de datos: Table 28
- Revenue de especializados: 55.8 % del total (£9,691,099)
 - *Cálculo:* Suma de revenue de perfiles especializados
 - $= £7,255,446 + £988,854 + £1,446,799 = £9,691,099$
 - $\frac{9,691,099}{17,364,360} = 0,5581 = 55,81\% \approx 55,8\%$
 - Fuente de datos: Table 28

- **Los segmentos especializados representan apenas el 15.2 % de las transacciones pero generan el 55.8 % del revenue total**, evidenciando un patrón extremadamente marcado del principio de Pareto. Este hallazgo demuestra que los clientes mayoristas y de lujo, aunque minoritarios en número, constituyen el motor principal de ingresos del negocio. Como documentan Khajvand et al. [20], este patrón es consistente con modelos RFM donde una minoría de clientes de alto valor genera la mayoría de los ingresos, principio fundamental para estrategias de priorización y asignación de recursos

Interpretación Estadística:

- **Significancia estadística:** Todas las pruebas con $p < 0,001$, muy por debajo del nivel estándar de $\alpha = 0,05$ establecido por Fisher [14]. Los valores extremadamente bajos de p-value (especialmente 5.70×10^{-135} para UnitPrice) indican que la probabilidad de que estos patrones sean producto del azar es prácticamente nula
- **Relevancia práctica:** 27.0 % de países con especialización. Aunque este porcentaje está por debajo del umbral idealizado del 30 % mencionado en la literatura [11], la relevancia práctica es innegable considerando que:
 - Los 10 países especializados generan el 55.8 % del revenue total
 - La especialización es altamente concentrada: Netherlands solo representa el 60.5 % de transacciones mayoristas
 - La distribución geográfica muestra patrones claros y coherentes (Europa para mayoristas, Mediterranean para lujo)
- **Poder explicativo:** Altamente significativo. Los mercados especializados generan 55.8 % del revenue con solo 15.2 % de las transacciones, resultando en un **ratio de eficiencia de 3.67x** ($\frac{55.8\%}{15.2\%} = 3,67$), lo que significa que cada transacción especializada genera en promedio 3.67 veces más ingresos que una transacción estándar

Conclusión Final:

Existe **EVIDENCIA ESTADÍSTICA SIGNIFICATIVA** ($p < 0,001$ en todas las pruebas) de que los datos anómalos en Total (mayoristas) y UnitPrice (lujo) están asociados sistemáticamente con países específicos, indicando diferencias reales y sustanciales en patrones de compra entre mercados geográficos.

La evidencia NO solo es estadísticamente significativa, sino que también tiene **relevancia práctica crítica para el negocio**: más de un cuarto de los países (27.0 %) muestran especialización clara en mayoristas, productos de lujo, o ambos, y estos países especializados generan más de la mitad del revenue total (55.8 %) con menos de un sexto de las transacciones (15.2 %).

Estos resultados son consistentes con la literatura de segmentación de clientes y análisis RFM en retail. Como documentan Chen et al. [5], Christy et al. [7] y Doğan et al. [11], la diferenciación geográfica es fundamental para estrategias comerciales efectivas, ya que los patrones de compra varían significativamente entre mercados según características culturales, económicas y estructurales. El presente análisis confirma y cuantifica esta variación, proporcionando una base sólida para la implementación de estrategias comerciales diferenciadas por geografía.

Implicaciones de Negocio:**Estrategias Recomendadas por Tipo de Mercado:**

Mercados Mayoristas (Netherlands, Australia, Sweden, Denmark, Japan):

- Desarrollar programas de descuentos por volumen escalonados (5 %, 10 %, 15 % según volumen)
- Implementar sistema de pedidos recurrentes (B2B) con plataforma digital dedicada
- Optimizar logística para envíos grandes (consolidación, frecuencia reducida, costos optimizados)
- Catálogo enfocado en productos de alta rotación con disponibilidad garantizada
- Atención personalizada para distribuidores con gerentes de cuenta dedicados
- Términos de pago flexibles (30/60/90 días) para facilitar flujo de efectivo B2B

Mercados de Lujo (Italy, Cyprus):

- Ampliar catálogo de productos premium con colecciones exclusivas
- Estrategia de pricing premium con posicionamiento aspiracional
- Marketing enfocado en exclusividad, calidad y diferenciación
- Packaging premium y presentación cuidada que refuerce percepción de valor
- Servicio al cliente de alto nivel con respuesta rápida y atención personalizada
- Experiencia de compra mejorada (presentación visual, descripciones detalladas, certificaciones)

Mercados Mixtos (Lebanon):

- Estrategia dual: volumen + calidad según segmento de cliente
- Atención a distribuidores especializados en productos premium
- Negociaciones personalizadas considerando perfil híbrido
- Portfolio adaptado con productos premium disponibles en volumen
- Flexibilidad en términos comerciales según tipo de compra

Estrategias Geográficas Generales:

- Segmentación de campañas de marketing por país según perfil identificado
- Adaptación de catálogo según perfil del mercado (más SKUs mayoristas en Netherlands, más premium en Italy)
- Pricing diferenciado por región considerando elasticidad y perfil de compra
- Logística optimizada según tipo de compra dominante (consolidación para mayoristas, envíos individuales express para lujo)
- Identificación de oportunidades de expansión en mercados con características similares a los especializados exitosos
- Priorización de recursos de marketing y ventas hacia los 10 países especializados que generan 55.8 % del revenue

Dashboard Ejecutivo Este dashboard permite al dueño del negocio **identificar especializaciones geográficas** en los patrones de compra de manera visual e intuitiva, respondiendo a las preguntas clave de negocio:

Métricas Globales del Negocio:

- Revenue Total: £17.4M
- Transacciones Mayoristas: 8.2 % del total
- Productos de Lujo: 8.4 % del total

Insights Clave Visualizados:

1. *¿Qué países tienen clientes mayoristas? (Panel superior izquierdo)*

- **Top 10 Países con Compras Mayoristas (B2B):** Netherlands (60.5 %), Japan (53.8 %), Australia (46.9 %), Sweden (39.1 %), Denmark (35.3 %), Singapore (31.0 %), Lebanon (28.9 %), Lithuania (27.3 %), Croatia (24.0 %), Norway (19.0 %)
- **Oportunidad de negocio:** Desarrollo de programas B2B especializados para estos mercados

2. *¿Dónde se venden productos de lujo? (Panel superior derecho)*

- **Top 10 Países con Productos de Lujo:** Lebanon (26.7 %), Italy (16.2 %), Cyprus (15.4 %), Poland (14.5 %), Finland (13.0 %), Belgium (13.8 %), Ireland (13.5 %), Nigeria (13.3 %), Spain (12.0 %), Malta (12.8 %)
- **Oportunidad de negocio:** Expansión de catálogo premium en estos mercados

3. *¿Qué segmento genera más ingresos? (Panel inferior izquierdo)*

- **Revenue por Tipo de Cliente:**
 - Minorista Estándar: £7.7M (44.2 % del total)
 - Mayorista Estándar: £7.3M (41.8 % del total)
 - Minorista Lujo: £1.0M (5.7 % del total)
 - Mayorista Lujo: £1.4M (8.3 % del total)
- **Hallazgo crítico:** Los segmentos Mayorista Estándar y Mayorista Lujo juntos generan £8.7M (50.1 % del revenue), demostrando la importancia estratégica del canal B2B

4. *¿Cuál es el volumen de cada segmento? (Panel inferior derecho)*

- **Volumen de Transacciones por Tipo:**
 - Minorista Estándar: 660,229 transacciones (84.8 %)
 - Mayorista Estándar: 53,177 transacciones (6.8 %)
 - Minorista Lujo: 55,834 transacciones (7.2 %)
 - Mayorista Lujo: 10,353 transacciones (1.3 %)
- **Hallazgo crítico:** Los segmentos especializados (mayoristas + lujo) representan solo 15.3 % de las transacciones pero generan 55.8 % del revenue, evidenciando el principio de Pareto

Decisiones Estratégicas Basadas en el Dashboard:

1. **Priorización de Mercados:** Enfocar esfuerzos comerciales en los 10 países mayoristas identificados (Netherlands, Japan, Australia, etc.) que generan desproporcionadamente más valor

2. **Estrategia de Producto:** Expandir catálogo premium en mercados de lujo identificados (Lebanon, Italy, Cyprus), donde la demanda por productos de alto valor está comprobada
3. **Asignación de Recursos:** Dado que los mayoristas generan 50.1 % del revenue con solo 8.1 % de las transacciones, asignar recursos especializados (gerentes de cuenta, términos preferenciales, soporte dedicado) para este segmento
4. **Diferenciación Geográfica:** Implementar estrategias comerciales diferenciadas por país según su perfil (mayorista vs lujo vs mixto), evitando el enfoque "one-size-fits-all"




Figura 54: Dashboard Ejecutivo - Análisis de Mercados: ¿Dónde están las oportunidades?

4.17. Hipótesis 3 - Patrones Temporales de Compra

Contexto

El dataset *Online Retail II* contiene transacciones entre diciembre 2009 y diciembre 2011 con información precisa de fecha y hora. Esta granularidad temporal permite analizar si existen **patrones temporales identificables** en el comportamiento de compra. Durante el análisis exploratorio se observaron fluctuaciones significativas en ventas a lo largo del tiempo, motivando la investigación de patrones cíclicos (semanales, mensuales), estacionales (anuales) o tendencias que permitan anticipar períodos de alta demanda.

Formulación de Hipótesis

- H_0 (**Hipótesis nula**): Las transacciones de compra NO presentan patrones temporales identificables. El comportamiento es aleatorio e impredecible, NO permitiendo anticipar períodos de alta demanda.
- H_1 (**Hipótesis alternativa**): Las transacciones de compra SÍ presentan patrones temporales identificables que permiten anticipar períodos de alta demanda y diseñar estrategias diferenciadas.

Predicciones Verificables

Si H_1 es correcta, deberíamos observar:

1. Diferencias estadísticamente significativas en ventas entre meses/trimestres ($p < 0,05$)
2. Noviembre y Diciembre con ventas superiores al 150 % del promedio mensual
3. Patrones diferenciados entre días laborables y fines de semana
4. Componente estacional superior al 15 % de la varianza en descomposición STL
5. Autocorrelación significativa en lags de 7 días (semanal) y 30 días (mensual)

El nivel de significancia de $\alpha = 0,05$ (95 % de confianza) sigue el estándar convencional en análisis estadístico establecido por Fisher [14] y ampliamente adoptado en la literatura de análisis de series temporales [3].

Metodología

El análisis se desarrolló en 7 pasos secuenciales:

- **Paso 1:** Preparación de variables temporales
- **Paso 2:** Análisis de estacionalidad mensual y trimestral
- **Paso 3:** Análisis de ciclos semanales
- **Paso 4:** Análisis de tendencia temporal
- **Paso 5:** Descomposición de series temporales (STL)
- **Paso 6:** Pruebas estadísticas
- **Paso 7:** Conclusión y estrategias de negocio

PASO 1: Preparación de Variables Temporales Objetivo

Transformar la variable **InvoiceDate** en múltiples features temporales para capturar patrones en diferentes escalas (anual, mensual, semanal, diaria y horaria).

Variables Creadas

Se extrajeron los siguientes componentes temporales de cada transacción:

Variable	Descripción
Year	Año de la transacción (2009, 2010, 2011)
Month	Mes numérico (1-12)
MonthName	Nombre del mes en español
Quarter	Trimestre (1-4)
QuarterName	Nombre descriptivo del trimestre
DayOfWeek	Día de la semana numérico (0=Lunes, 6=Domingo)
DayName	Nombre del día en español
Hour	Hora del día (0-23)
Date	Fecha completa sin hora
YearMonth	Período año-mes
WeekOfYear	Semana del año (1-52)
IsWeekend	Variable binaria (1=fin de semana, 0=laborable)
Total	Revenue de la transacción (Quantity × UnitPrice)

Tabla 30: Variables temporales creadas para el análisis

Agregaciones Temporales

Se crearon cuatro niveles de agregación para el análisis:

1. **Agregación Diaria:** 604 días únicos con métricas de revenue, transacciones, clientes y ticket promedio
2. **Agregación Mensual:** 25 meses con revenue total, número de transacciones y clientes únicos
3. **Agregación Trimestral:** 9 trimestres con las mismas métricas
4. **Agregación por Día de la Semana:** 7 días con promedios históricos

Resultados de la Preparación

Métrica	Valor
Período de análisis	2009-12-01 a 2011-12-09
Total transacciones	778,793
Total días únicos	604
Total meses únicos	25
Años incluidos	2009, 2010, 2011
Revenue total	£17,364,360.26
Revenue diario promedio	£28,748.94
Revenue mensual promedio	£694,574.41
Transacciones diarias promedio	61

Tabla 31: Resumen estadístico del período de análisis

La preparación de variables temporales permitió establecer una base sólida para el análisis multi-dimensional posterior, facilitando la identificación de patrones a diferentes escalas temporales.

PASO 2: Análisis de Estacionalidad Mensual y Trimestral Objetivo

Identificar patrones estacionales anuales analizando la distribución de ventas por mes y trimestre. Se busca determinar si existen períodos de alta y baja demanda predecibles.

Métricas Analizadas

- Revenue total por mes y trimestre
- Número de transacciones
- Variación porcentual respecto al promedio
- Identificación de temporadas altas (>150 % del promedio)

Resultados del Análisis Mensual

Mes	Revenue (£)	% Revenue	Trans.	% Promedio
Enero	1,122,868.88	6.47 %	1,996	77.60 %
Febrero	950,643.88	5.47 %	2,101	65.70 %
Marzo	1,291,060.23	7.44 %	2,845	89.22 %
Abril	1,059,613.31	6.10 %	2,475	73.23 %
Mayo	1,274,335.85	7.34 %	2,931	88.07 %
Junio	1,295,799.35	7.46 %	2,887	89.55 %
Julio	1,184,850.21	6.82 %	2,706	81.88 %
Agosto	1,245,208.20	7.17 %	2,570	86.05 %
Septiembre	1,777,726.00	10.24 %	3,442	122.85 %
Octubre	2,068,754.46	11.91 %	4,062	142.97 %
Noviembre	2,322,364.70	13.37 %	5,243	160.49 %
Diciembre	1,771,135.18	10.20 %	3,690	122.40 %

Tabla 32: Revenue mensual agregado (2009-2011)

Del análisis mensual se identificó que **Noviembre** es el único mes que supera el umbral del 150 % del promedio mensual, representando el 13.37 % del revenue anual total y alcanzando el 160.49 % del promedio. Este hallazgo es consistente con la literatura sobre estacionalidad en retail, donde Taylor [25] documentan que los meses de noviembre y diciembre típicamente representan entre el 20-30 % de las ventas anuales en el comercio minorista debido a la temporada de compras navideñas.

Meses de Temporada Alta y Baja

- **Temporada ALTA** (>150 % promedio): Noviembre únicamente
- **Temporada BAJA** (<70 % promedio): Febrero (65.70 %)
- **Variación máxima**: 144.3 % entre el mes más alto y más bajo




Figura 55: Revenue por mes con selector de año. Las barras rojas indican meses con ventas >150 % del promedio




Figura 56: Variación porcentual vs promedio por mes. Línea roja: 100 % (promedio); Línea punteada: 150 % (temporada alta)

Resultados del Análisis Trimestral

Trimestre	Revenue (£)	% Revenue	Trans.	% Promedio
Q1 (Ene-Mar)	3,364,572.99	19.38 %	6,942	77.51 %
Q2 (Abr-Jun)	3,629,748.51	20.90 %	8,293	83.61 %
Q3 (Jul-Sep)	4,207,784.41	24.23 %	8,718	96.93 %
Q4 (Oct-Dic)	6,162,254.34	35.49 %	12,995	141.95 %

Tabla 33: Revenue trimestral agregado (2009-2011)

El análisis trimestral revela que el **Q4 (Oct-Dic)** concentra más de un tercio del revenue anual (35.49 %), superando significativamente el promedio trimestral (141.95 %). Este patrón es característico del retail y refleja el efecto combinado de la temporada de compras navideñas y las promociones de fin de año, como documentan Kesavan et al. [19] en su estudio sobre patrones estacionales en inventarios de retail.




Figura 57: Revenue por trimestre con selector de año




Figura 58: Distribución porcentual del revenue por trimestre. El segmento resaltado indica temporada alta

Heatmap de Evolución Temporal

Para analizar la evolución año a año de los patrones estacionales, se construyó un heatmap que muestra el revenue mensual para cada año del período analizado:




Figura 59: Heatmap de revenue por año y mes. Los colores más intensos indican mayor revenue

El heatmap (Figure 59) revela la consistencia de los patrones estacionales a lo largo de los años, con concentración de revenue en los meses de septiembre a noviembre de manera recurrente. Esta visualización confirma que los patrones observados no son eventos aislados sino tendencias sistemáticas del negocio.

Conclusiones del Paso 2

1. El mes con mayor revenue es **Noviembre** (£2,322,364.70), representando el 13.4% del revenue anual
2. El trimestre con mayor revenue es **Q4** (£6,162,254.34), representando el 35.5% del revenue anual
3. Se identificó **UN mes** de temporada alta (>150% promedio): Noviembre
4. Se identificó **UN mes** de temporada baja (<70% promedio): Febrero
5. La variación entre el mes más alto y más bajo es del 144.3%
6. Los patrones estacionales son consistentes año tras año

PASO 3: Análisis de Ciclos Semanales Objetivo

Identificar patrones de comportamiento de compra según el día de la semana, diferenciando entre días laborables y fines de semana. Se busca determinar si existen diferencias sistemáticas que puedan asociarse a tipos de clientes (B2B mayoristas vs B2C minoristas).

Hipótesis de Comportamiento

- **Días laborables (Lun-Vie):** Mayor actividad de clientes B2B mayoristas
- **Fines de semana (Sáb-Dom):** Mayor actividad de clientes B2C minoristas
- **Lunes:** Posible acumulación de pedidos del fin de semana
- **Viernes:** Preparación para compras de fin de semana

Resultados por Día de la Semana

Día	Revenue (£)	% Revenue	Trans.	Ticket (£)	% Prom.
Lunes	2,776,303.32	15.99 %	5,748	483.00	111.92 %
Martes	3,320,131.65	19.12 %	6,622	501.38	133.84 %
Miércoles	3,018,440.11	17.38 %	6,646	454.17	121.68 %
Jueves	3,744,314.45	21.56 %	7,769	481.96	150.94 %
Viernes	2,728,473.17	15.71 %	5,387	506.49	109.99 %
Sábado	9,803.05	0.06 %	30	326.77	0.40 %
Domingo	1,766,894.50	10.18 %	4,746	372.29	71.23 %

Tabla 34: Revenue y métricas por día de la semana (agregado 2009-2011)

El análisis revela que el **Jueves** es el día de mayor actividad comercial, representando el 21.56 % del revenue semanal y alcanzando el 150.94 % del promedio diario. Este patrón, junto con la concentración del 93.94 % del revenue en días laborables, sugiere fuertemente un modelo de negocio B2B, consistente con los hallazgos de Anderson [1] sobre patrones temporales en comercio electrónico mayorista.




Figura 60: Revenue por día de la semana. Azul: días laborables; Rojo: fin de semana




Figura 61: Número de transacciones por día de la semana

Comparación Laborables vs Fin de Semana

Tipo de Día	Revenue/Día (£)	Trans./Día	Ticket (£)	Núm. Días
Laborables	30,927.90	64	484.51	504
Fin de Semana	17,766.98	48	372.01	100
Diferencia	+74.1 %	+33.3 %	+30.2 %	—

Tabla 35: Comparación de métricas entre días laborables y fin de semana

Los días laborables generan un **74.1 % más de revenue promedio** que los fines de semana, con tickets promedio un 30.2 % superiores. Esta diferencia sustancial confirma la predominancia de clientes B2B (mayoristas) que operan en horario comercial estándar, como se documenta en la literatura de análisis temporal de ventas [26].




Figura 62: Ticket promedio por día de la semana




Figura 63: Comparación de revenue y transacciones: laborables vs fin de semana

Conclusiones del Paso 3

1. El día con mayor revenue es **Jueves** (£3,744,314.45), representando el 21.6 % del revenue semanal
2. El día con menor revenue es **Sábado** (£9,803.05), con apenas el 0.1 % del revenue semanal
3. Los días laborables generan un **74.1 % más revenue promedio** que los fines de semana
4. El ticket promedio en días laborables (£484.51) es 30.2 % superior al de fin de semana (£372.01)
5. La variación entre el día más alto y más bajo es del 38,095.4 %
6. Patrón identificado: **MAYOR actividad en días LABORABLES** → Predominancia de clientes **B2B (mayoristas)**

PASO 4: Análisis de Tendencia Temporal **Objetivo**

Analizar la evolución temporal de las ventas para identificar tendencias generales de crecimiento, estancamiento o decrecimiento del negocio a lo largo del período 2009-2011.

Métricas de Tendencia

- Revenue diario, mensual y trimestral
- Promedio móvil de 7 días (MA7) y 30 días (MA30)
- Tasa de crecimiento mensual y anual
- Volatilidad de la serie temporal

Los promedios móviles son técnicas estándar en análisis de series temporales propuestas por Box et al. [3] para suavizar fluctuaciones de corto plazo y revelar tendencias subyacentes. El MA7 captura patrones semanales mientras que el MA30 identifica tendencias mensuales.

Estadísticas de la Serie Temporal Diaria

Métrica	Valor
Período	2009-12-01 a 2011-12-09
Días totales	604
Media	£28,748.94
Mediana	£25,544.04
Desviación Estándar	£16,011.92
Mínimo	£3,439.67
Máximo	£184,347.66

Tabla 36: Estadísticas de la serie temporal diaria de revenue




Figura 64: Tendencia de revenue diario con promedios móviles. Línea azul clara: revenue diario; Línea naranja: MA7; Línea roja: MA30

La Figure 64 muestra la evolución diaria del revenue con sus promedios móviles. Se observa alta volatilidad en el corto plazo (línea azul clara) que es suavizada por el MA7 (naranja) y especialmente por el MA30 (rojo), revelando una tendencia relativamente estable con picos estacionales recurrentes.

Crecimiento Año a Año (YoY)

Año	Revenue (£)	Trans.	Clientes	Crec. Revenue
2009	683,504.01	1,512	955	—
2010	8,368,013.10	18,316	4,226	+1,124.3 %
2011	8,312,843.14	17,120	4,214	-0.7 %

Tabla 37: Crecimiento año a año (YoY)

El crecimiento dramático de 2009 a 2010 (+1,124.3%) se debe a que 2009 solo incluye datos de diciembre (primer mes de operación), mientras que 2010 y 2011 representan años completos. La ligera caída de -0.7% entre 2010 y 2011 sugiere estabilización del negocio.




Figura 65: Evolución mensual del revenue (2009-2011)




Figura 66: Tasa de crecimiento mensual. Verde: crecimiento; Rojo: decrecimiento

Análisis de Volatilidad

La volatilidad del revenue diario se calculó como el coeficiente de variación:

$$\text{Volatilidad} = \frac{\sigma}{\mu} \times 100 = \frac{16,011,92}{28,748,94} \times 100 = 55,7 \%$$

Una volatilidad del 55.7% indica **variabilidad moderada**, característica de series temporales con estacionalidad pronunciada, como documentan Hyndman et al. [18] en su análisis de patrones de demanda en retail.




Figura 67: Comparación año a año del revenue total

Conclusiones del Paso 4

1. **Tendencia general:** CRECIENTE (+1,116.2 % de 2009 a 2011)
2. **Tasa de crecimiento promedio mensual:** 2.71 %
3. **Mayor crecimiento mensual:** Septiembre 2011 (+47.7 %)
4. **Mayor decrecimiento mensual:** Diciembre 2011 (-55.3 %)
5. **Volatilidad:** 55.7 % (moderada)
6. El negocio muestra **estacionalidad recurrente** con picos en Q4
7. Estabilización del crecimiento entre 2010 y 2011

PASO 5: Descomposición de Series Temporales (STL) Objetivo

Descomponer la serie temporal de ventas en sus componentes fundamentales (tendencia, estacionalidad y residuo) utilizando el método STL (Seasonal and Trend decomposition using Loess). Esto permite cuantificar la importancia de cada componente y validar la existencia de patrones temporales.

Método STL

La descomposición STL fue propuesta por Cleveland et al. [8] como un método robusto para separar series temporales en componentes interpretables. El método utiliza regresión local (LOESS) iterativa para estimar:

- **Tendencia (T_t):** Dirección general de largo plazo
- **Estacionalidad (S_t):** Patrones cíclicos recurrentes
- **Residuo (R_t):** Variaciones aleatorias no explicadas

La descomposición aditiva asume: $Y_t = T_t + S_t + R_t$

Se utilizó un período de 365 días para capturar estacionalidad anual, siguiendo las recomendaciones de Hyndman et al. [18] para datos de frecuencia diaria.

Resultados de la Descomposición

Componente	Varianza	% Varianza Explicada
Original	256,381,471.48	100.00 %
Tendencia	77,541.28	0.03 %
Estacionalidad	173,538,964.91	67.70 %
Residuo	85,096,887.27	33.19 %

Tabla 38: Varianza de componentes STL

Métricas de Fuerza

Se calcularon las métricas de fuerza propuestas por Wang et al. [30] para cuantificar la importancia relativa de cada componente:

Fuerza de Estacionalidad:

$$F_s = \max \left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)} \right) = 0,6710$$

Fuerza de Tendencia:

$$F_t = \max \left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(T_t + R_t)} \right) = 0,0001$$

Interpretación:

- $F_s = 0,6710 > 0.15 \rightarrow$ **Estacionalidad SIGNIFICATIVA**
- $F_t = 0,0001 < 0.15 \rightarrow$ Tendencia NO significativa

El umbral de 0.15 es el estándar establecido por Wang et al. [30] para determinar si un componente tiene importancia práctica en la predicción de la serie.



Figura 68: Descomposición STL completa. De arriba a abajo: serie original, tendencia, estacionalidad y residuo

La Figure 68 muestra claramente que el componente estacional domina la variabilidad de la serie, mientras que la tendencia es prácticamente plana (explicando solo 0.03 % de la varianza).




Figura 69: Patrón estacional anual extraído (primer ciclo de 365 días)

El patrón estacional (Figure 69) revela claramente los períodos de alta demanda hacia el final del año (días 270-330, correspondientes a septiembre-noviembre), con una amplitud de £77,042.75 entre el máximo y el mínimo.




Figura 70: Distribución de los componentes STL




Figura 71: Varianza explicada por cada componente STL

Análisis de Autocorrelación

Se calculó la función de autocorrelación (ACF) para identificar dependencias temporales, utilizando el método propuesto por Box et al. [3]. La ACF mide la correlación entre la serie y sus versiones rezagadas (lags).

Lag	ACF	Interpretación
7 días	0.418	Patrón semanal SIGNIFICATIVO
30 días	0.146	Patrón mensual detectado
Total lags significativos	50	Alta autocorrelación general

Tabla 39: Autocorrelación en lags clave

La presencia de autocorrelación significativa en lag 7 ($ACF=0.418$) confirma patrones semanales recurrentes, mientras que el lag 30 ($ACF=0.146$) indica ciclos mensuales, ambos consistentes con comportamiento estacional en retail documentado por Hyndman et al. [18].




Figura 72: Función de Autocorrelación (ACF). Líneas rojas: intervalo de confianza 95 %; Líneas verdes: lags clave (7, 30, 365)

Conclusiones del Paso 5

1. **Componente estacional:** Explica el 67.70 % de la varianza (DOMINANTE)
2. **Componente de tendencia:** Explica solo el 0.03 % (prácticamente nula)
3. **Residuo:** 33.19 % (variabilidad aleatoria moderada)
4. **Fuerza de estacionalidad:** $F_s = 0,6710 > 0.15 \rightarrow$ SIGNIFICATIVA
5. **Fuerza de tendencia:** $F_t = 0,0001 < 0.15 \rightarrow$ No significativa
6. **Amplitud estacional:** £77,042.75 (diferencia máx-mín)
7. **Autocorrelación:** Patrones semanales (lag 7) y mensuales (lag 30) confirmados
8. **Conclusión:** La serie presenta **ESTACIONALIDAD SIGNIFICATIVA** pero tendencia débil

PASO 6: Pruebas Estadísticas Objetivo

Validar estadísticamente la existencia de patrones temporales mediante pruebas de hipótesis formales. Se busca determinar si las diferencias observadas son estadísticamente significativas o podrían deberse al azar.

Nivel de Significancia

Todas las pruebas utilizan $\alpha = 0,05$ (95 % de confianza), siguiendo el estándar convencional establecido por Fisher [14].

Criterio de Decisión:

- $p < 0,05 \rightarrow$ Rechazamos H_0 (diferencia significativa)
- $p \geq 0,05 \rightarrow$ No rechazamos H_0 (sin evidencia suficiente)

TEST 1: Kruskal-Wallis - Revenue por Mes

El test de Kruskal-Wallis [?] es una prueba no paramétrica que evalúa si tres o más grupos independientes provienen de la misma distribución. Se seleccionó este test porque no asume normalidad en los datos, lo cual es apropiado para datos de revenue que típicamente presentan distribuciones asimétricas [9].

Hipótesis:

- H_0 : Todos los meses tienen la misma distribución de revenue
- H_1 : Al menos un mes difiere significativamente

Resultado:

- Estadístico H = 4,666.03
- Grados de libertad = 11
- P-value <1e-300

Conclusión: $p < 0,05 \rightarrow$ RECHAZAMOS H_0

Existen DIFERENCIAS SIGNIFICATIVAS en revenue entre meses. Los patrones mensuales NO son producto del azar.

TEST 2: Kruskal-Wallis - Revenue por Trimestre

Misma metodología aplicada a nivel trimestral.

Resultado:

- Estadístico H = 3,365.13
- Grados de libertad = 3
- P-value <1e-300

Conclusión: $p < 0,05 \rightarrow$ RECHAZAMOS H_0

Existen DIFERENCIAS SIGNIFICATIVAS en revenue entre trimestres. Los patrones trimestrales NO son producto del azar.

TEST 3: Mann-Whitney U - Laborables vs Fin de Semana

El test de Mann-Whitney U [22] compara dos grupos independientes y es la alternativa no paramétrica al t-test. Fue seleccionado porque los datos de revenue no cumplen el supuesto de normalidad requerido por pruebas paramétricas [23].

Hipótesis:

- H_0 : Laborables y fin de semana tienen la misma distribución
- H_1 : Los grupos difieren significativamente

Datos:

- Días Laborables: $n = 648,351$, mediana=£13.20
- Fin de Semana: $n = 130,442$, mediana=£7.50

Resultado:

- Estadístico U = 52,410,734,594.5
- **P-value < 1e-300**

Conclusión: $p < 0,05 \rightarrow$ **RECHAZAMOS H_0**

Existen DIFERENCIAS SIGNIFICATIVAS entre días laborables y fin de semana. La diferencia en mediana es del 76.0 % (más alto en laborables).

TEST 4: Kruskal-Wallis - Revenue por Día de la Semana**Resultado:**

- Estadístico H = 19,763.16
- Grados de libertad = 6
- **P-value < 1e-300**

Conclusión: $p < 0,05 \rightarrow$ **RECHAZAMOS H_0**

Existen DIFERENCIAS SIGNIFICATIVAS entre días de la semana. Los patrones semanales NO son producto del azar.

TEST 5: Augmented Dickey-Fuller - Estacionariedad

El test de Augmented Dickey-Fuller (ADF) [10] evalúa si una serie temporal es estacionaria (sin tendencia estocástica). Una serie estacionaria tiene propiedades estadísticas constantes en el tiempo, requisito fundamental para muchos modelos de forecasting [3].

Hipótesis:

- H_0 : La serie tiene raíz unitaria (NO estacionaria)
- H_1 : La serie ES estacionaria

Resultado - Serie Original:

- Estadístico ADF = -2.125
- P-value = 0.235
- Valores críticos: 1 % = -3.439, 5 % = -2.866, 10 % = -2.569

Conclusión: $p \geq 0,05 \rightarrow$ **NO RECHAZAMOS H_0**

La serie original NO ES ESTACIONARIA. Presenta tendencia estocástica (raíz unitaria).

Resultado - Serie Diferenciada:

- Estadístico ADF = -10.189
- **P-value = 6.40e-18**

Conclusión: $p < 0,05 \rightarrow$ **RECHAZAMOS H_0**

La serie diferenciada SÍ ES ESTACIONARIA. La diferenciación de primer orden (I(1)) es suficiente para lograr estacionariedad, lo cual es típico en series temporales de ventas [18].

Tabla Resumen de Pruebas Estadísticas

Prueba	Estadístico	P-value	Resultado	Interpretación
Kruskal-Wallis (Meses)	4,666.03	<1e-300	Rechazar H_0	Diferencias significativas entre meses
Kruskal-Wallis (Trimestres)	3,365.13	<1e-300	Rechazar H_0	Diferencias significativas entre trimestres
Kruskal-Wallis (Días Semana)	19,763.16	<1e-300	Rechazar H_0	Diferencias significativas entre días
Mann-Whitney U (Lab vs WE)	5.24e10	<1e-300	Rechazar H_0	Diferencias entre laborables y fin de semana
ADF (Estacionariedad)	-2.125	0.235	No rechazar H_0	Serie no estacionaria

Tabla 40: Resumen de todas las pruebas estadísticas

Conclusiones del Paso 6

- Pruebas realizadas:** 5 (4 sobre patrones temporales + 1 sobre estacionariedad)
- Pruebas significativas** ($p < 0,05$): 4/4 (100 % sobre patrones temporales)
- Patrones validados estadísticamente:**
 - Estacionalidad mensual confirmada ($p < 1e-300$)
 - Estacionalidad trimestral confirmada ($p < 1e-300$)
 - Ciclos semanales confirmados ($p < 1e-300$)
 - Diferencia laborables/fin de semana confirmada ($p < 1e-300$)
- Características de la serie:**
 - Serie original NO estacionaria (ADF $p = 0,235$)
 - Serie diferenciada SÍ estacionaria (ADF $p = 6,40e-18$)
 - Proceso integrado de orden 1: I(1)
- Validación de H_1 :** CONFIRMADA CON ALTA CONFIANZA
 - 4 de 4 pruebas muestran patrones significativos
 - Las diferencias NO son producto del azar
 - Evidencia estadística sólida de patrones temporales

PASO 7: Conclusión Final y Estrategias de Negocio Consolidación de Hallazgos

Dimensión	Hallazgo Principal
Estacionalidad	Noviembre: mes pico (160.5 % del promedio) Q4: trimestre dominante (35.5 % del revenue anual)
Ciclos Semanales	Jueves: día de mayor actividad (21.6 % revenue semanal) Laborables: 74.1 % más revenue que fin de semana
Tendencia	Crecimiento total: +1,116.2 % (2009-2011) Dirección: CRECIENTE con estabilización 2010-2011
Descomposición STL	Estacionalidad: 67.70 % de la varianza ($F_s = 0,671$) Tendencia: 0.03 % de la varianza ($F_t = 0,0001$)
Validación	4/4 pruebas estadísticas significativas ($p < 0,05$)

Tabla 41: Resumen consolidado de hallazgos

Verificación de Predicciones

Predicción	Estado	Evidencia
Diferencias significativas entre períodos	Bien	$p < 0,05$ en todas las pruebas
Nov y Dic >150 % del promedio	Mal	Solo Noviembre (160.5 %)
Diferencias laborables vs fin de semana	Bien	74.1 % más revenue ($p < 1e-300$)
Componente estacional >15 %	Bien	67.70 % de varianza explicada
Autocorrelación en lags clave	Bien	Lag 7: ACF=0.418; Lag 30: ACF=0.146
Total cumplidas	4/5	80.0 %

Tabla 42: Verificación de predicciones verificables

Decisión Final sobre las Hipótesis

Criterios de Validación:

- Validación estadística ($\geq 3/4$ pruebas significativas): (4/4)
- Componentes STL significativos (F_s o $F_t > 0,15$): ($F_s = 0,671$)
- Predicciones cumplidas ($\geq 3/5$): (4/5 = 80 %)

DECISIÓN: RECHAZAR H_0 Y ACEPTAR H_1

CONFIANZA: ALTA

Las transacciones SÍ presentan patrones temporales identificables que permiten anticipar demanda y diseñar estrategias diferenciadas.

Justificación:

- Evidencia estadística sólida:** Las 4 pruebas de hipótesis realizadas sobre patrones temporales rechazaron la hipótesis nula con $p < 1e-300$, indicando diferencias extremadamente significativas que no pueden atribuirse al azar
- Componente estacional dominante:** La descomposición STL reveló que el 67.70 % de la variabilidad en las ventas se explica por estacionalidad ($F_s = 0,671$ 0,15), muy por encima del umbral de significancia práctica
- Patrones consistentes y recurrentes:** Los análisis muestran que los patrones se repiten año tras año de manera sistemática, no son eventos aislados

4. **Alto cumplimiento de predicciones:** 4 de 5 predicciones verificables se cumplieron (80 %), incluyendo todas las predicciones sobre significancia estadística y componentes temporales
5. **Relevancia práctica:** Las diferencias observadas son sustanciales desde una perspectiva de negocio (ej: 74.1 % más revenue en laborables, Noviembre con 160.5 % del promedio), no solo estadísticamente significativas

Recomendaciones Estratégicas de Negocio

Basándose en la evidencia de patrones temporales identificables, se proponen las siguientes estrategias:

1. GESTIÓN DE INVENTARIO

■ **Temporada alta (Octubre-Noviembre):**

- Incrementar stock en **Octubre** (+60 % sobre nivel base) para anticipar demanda de Noviembre
- Nivel de inventario objetivo: +160 % sobre el promedio mensual
- Productos prioritarios: Identificar top SKUs de temporada usando análisis histórico

■ **Temporada baja (Febrero):**

- Reducir inventario en Enero (-30 % sobre nivel base)
- Implementar promociones de liquidación para productos estacionales

2. ESTRATEGIA DE MARKETING

■ **Temporada alta (Q4):**

- Maximizar presupuesto de marketing en septiembre-noviembre (60 % del presupuesto anual)
- Campañas agresivas 3-4 semanas antes de Noviembre
- Enfoque en canales B2B (LinkedIn, email corporativo) dado el perfil mayorista

■ **Temporada baja (Q1):**

- Promociones y descuentos: 15-25 % para estimular demanda
- Campañas de fidelización para mantener engagement

■ **Días específicos:**

- **Jueves:** Lanzamiento de campañas semanales (día de mayor actividad)
- **Lunes-Martes:** Email marketing B2B (inicio de semana laboral)

3. GESTIÓN DE RECURSOS HUMANOS

■ **Personal operativo:**

- Incrementar staff en +40 % durante Octubre-Noviembre
- Personal temporal contratado con 2 meses de anticipación

■ **Horarios:**

- Priorizar cobertura en días laborables (especialmente jueves)
- Reducir operaciones de fin de semana (solo 6.1 % del revenue)
- Considerar operación 5 días/semana en temporada baja

4. FORECASTING Y MONITOREO

■ Modelos predictivos:

- Implementar modelo SARIMA (Seasonal ARIMA) dado que la serie es $I(1)$ con estacionalidad fuerte
- Reentrenamiento mensual con datos actualizados
- Horizonte de predicción: 3-6 meses adelante

■ KPIs de monitoreo:

- Revenue diario vs forecast (umbral: $\pm 20\%$)
- Tasa de crecimiento mensual vs histórico
- **Alertas automáticas:** Revenue diario $< 80\%$ del esperado

■ Dashboard en tiempo real:

- Revenue actual vs forecast por día/semana/mes
- Comparación YoY (Year-over-Year)
- Indicadores de estacionalidad (posición en el ciclo)

5. ESTRATEGIA DE PRECIOS

■ Pricing dinámico:

- Precios premium en temporada alta (Q4): $+5-10\%$
- Descuentos estratégicos en temporada baja (Q1): $-15-25\%$

■ Promociones B2B:

- Descuentos por volumen incrementados en días laborables
- Ofertas especiales jueves (día pico de actividad)

Impacto Esperado de las Estrategias

Si se implementan correctamente estas recomendaciones, se espera:

- Reducción del 20-30 % en quiebres de stock durante temporada alta
- Mejora del 15-20 % en la precisión del forecast de demanda
- Optimización de costos de personal del 10-15 % (mejor alineación con demanda)
- Incremento del 5-10 % en revenue anual por mejor capitalización de temporada alta
- Reducción del 25-35 % en inventario obsoleto (mejor gestión de temporada baja)

Conclusión Final

El análisis exhaustivo de 778,793 transacciones a lo largo de 2 años demuestra de manera concluyente que los patrones de compra en este negocio son **altamente predecibles y estacionales**. La evidencia estadística es abrumadora: el 67.70 % de la variabilidad en las ventas se explica por estacionalidad, con patrones consistentes que se validan mediante múltiples pruebas estadísticas ($p < 1e-300$).

La identificación de estos patrones temporales no es solo académicamente interesante, sino que tiene implicaciones estratégicas directas. El negocio puede ahora anticipar con alta confianza que:

- Noviembre generará aproximadamente 160 % del revenue mensual promedio
- Q4 concentrará el 35 % del revenue anual
- Los días laborables superarán en 74 % al revenue de fin de semana
- El jueves será el día de mayor actividad comercial

Estos insights permiten una planificación estratégica informada en todas las áreas del negocio: inventario, marketing, recursos humanos, pricing y forecasting. La implementación de las estrategias recomendadas debería traducirse en mejoras medibles en eficiencia operativa y rentabilidad.

CONCLUSIÓN HIPÓTESIS 3

Se **RECHAZA** la hipótesis nula (H_0) y se **ACEPTA** la hipótesis alternativa (H_1) con **ALTA CONFIANZA**.

Las transacciones de compra **SÍ presentan patrones temporales identificables, predecibles y accionables** que permiten anticipar períodos de alta demanda y diseñar estrategias diferenciadas por período temporal.

Evidencia: 4/4 pruebas estadísticas significativas, 67.70 % de varianza explicada por estacionalidad, 4/5 predicciones cumplidas, patrones consistentes año tras año.

5. Conclusiones Generales

El análisis exploratorio y validación de hipótesis del dataset *Online Retail II* [4] reveló patrones significativos y accionables tras un proceso riguroso de limpieza, exploración y validación estadística. El dataset original contenía 1,033,036 transacciones; el análisis final se realizó sobre 778,793 transacciones válidas (75.5 %), 5,942 clientes únicos, 46 países, período diciembre 2009 - diciembre 2011, con revenue total de £17,364,360.26.

- **Análisis Exploratorio de Datos (EDA):** El proceso de limpieza identificó 235,151 registros (23.0 %) con **CustomerID** nulo, 1,454 con **Description** nulo, 34,335 facturas canceladas (prefijo "C"), y registros con **UnitPrice** o **Quantity** ≤ 0 . Se normalizaron 46 países (EIRE \rightarrow Ireland, USA \rightarrow United States, RSA \rightarrow South Africa) eliminando valores ambiguos. La detección de outliers mediante método IQR [28] identificó 8.16 % en **Total** y 8.40 % en **UnitPrice**. Siguiendo Khandelwal [21], se conservaron estos outliers por representar segmentos estratégicos (mayoristas, productos premium, clientes VIP) en lugar de ruido estadístico. El análisis de distribuciones reveló concentración en productos de bajo precio (mediana £1.25) con alta dispersión, y cantidades típicamente bajas (mediana 3 unidades) con pedidos mayoristas ocasionales.
- **Hipótesis 1 - Concatenación de CustomerID (RECHAZADA):** Mediante expresiones regulares se buscaron patrones de 5 dígitos en **Description** de registros nulos, encontrando solo 240 casos (0.10 % de los nulos), de los cuales 219 coincidían con **CustomerID** reales (91.25 % de precisión). Sin embargo, esta recuperación representa únicamente el **0.09 % del total de 235,151 nulos**, siendo estadísticamente insignificante ($<1\%$ threshold). El análisis de control reveló que los números encontrados (serie 17xxx como "SET 10 CARDS HANGING BAUBLES 17080") corresponden a códigos de producto estándar del catálogo, no a concatenación errónea. **Conclusión: SE RECHAZA H_1 Y SE ACEPTA H_0 .** Los 234,932 nulos restantes (99.91 %) se atribuyen a compras sin registro, ventas B2B sin **CustomerID**, o errores sistemáticos de captura.
- **Hipótesis 2 - Anomalías Geográficas (ACEPTADA):** El análisis mediante clasificación en 4 perfiles (Minorista Estándar 85.87 %, Mayorista Estándar 7.15 %, Minorista Lujo 6.64 %, Mayorista Lujo 0.34 %) y pruebas estadísticas confirmó asociación sistemática entre outliers y

países específicos. Test Chi-cuadrado ($\chi^2 = 15,234,56$, $p < 1e-300$) y Kruskal-Wallis ($H = 8,945,23$, $p < 1e-300$) rechazaron la hipótesis nula de distribución uniforme. Se identificaron especializaciones claras: *mercados mayoristas* Países Bajos (47.2%), Suecia (42.8%), Australia (41.3%); *mercados de lujo* Italia (23.1%), Chipre (21.8%), Portugal (19.7%); *mercado mixto* Portugal único con especialización dual (26.4% mayorista + 19.7% lujo). Estas diferencias son estadísticamente significativas y requieren estrategias comerciales diferenciadas por mercado [11, 31, 12]. **Conclusión: SE RECHAZA H_0 Y SE ACEPTA H_1** con alta confianza.

- **Hipótesis 3 - Patrones Temporales (ACEPTADA):** El análisis de series temporales confirmó patrones altamente predecibles mediante 4 pruebas con $p < 1e-300$: Kruskal-Wallis mensual ($H = 4,666,03$), trimestral ($H = 3,365,13$), semanal ($H = 19,763,16$), y Mann-Whitney laborales vs fin de semana ($U = 5,24 \times 10^{10}$). La descomposición STL [8] reveló que el **67.70 % de la varianza se explica por estacionalidad** ($F_s = 0,671 \gg 0,15$), con tendencia prácticamente nula ($F_t = 0,0001$). Patrones identificados: (1) *Estacionalidad anual*: Q4 concentra 35.5% del revenue, noviembre alcanza 160.5% del promedio mensual; (2) *Ciclos semanales*: 74.1% más revenue en laborales vs fin de semana, jueves como día pico (21.6% revenue semanal), ticket promedio 30.2% superior en laborales (£484.51 vs £372.01); (3) *Autocorrelación*: significativa en lags 7 días (ACF=0.418) y 30 días (ACF=0.146). Test ADF confirmó serie I(1) estacionaria tras diferenciación ($p = 6,40e-18$) [10, 3]. **Conclusión: SE RECHAZA H_0 Y SE ACEPTA H_1** con alta confianza.
- **Segmentación de clientes y valor estratégico:** Los 4 perfiles identificados revelan estructura comercial clara donde el segmento Minorista Estándar domina en volumen (85.87% transacciones) pero genera solo 56.21% del revenue, mientras que los mayoristas (7.49% transacciones) aportan 34.21% del revenue con tickets 5-10 veces superiores. Esta concentración de valor en segmento minoritario justifica estrategias de retención diferenciadas y atención personalizada B2B [5, 13]. La predominancia de actividad en días laborales (93.94% del revenue) confirma modelo de negocio B2B mayorista.
- **Tendencia temporal y crecimiento:** La serie muestra crecimiento dramático del 1,116.2% entre 2009-2011, explicado parcialmente por inicio en diciembre 2009 versus años completos 2010-2011. La estabilización en 2011 (-0.7% vs 2010) indica maduración del mercado. Volatilidad moderada (55.7%) y naturaleza I(1) la hacen apropiada para modelos SARIMA de forecasting con horizontes de 3-6 meses [17, 25].
- **Validación estadística y robustez:** Las 6 pruebas de hipótesis aplicadas (4 para H3, 2 para H2) rechazaron consistentemente las hipótesis nulas de aleatoriedad con $p < 1e-300$, proporcionando evidencia abrumadora de que los patrones observados son reales, reproducibles y no atribuibles al azar [14]. La magnitud de los p-values ($< 1e-300$) indica significancia estadística extrema, muy superior al umbral convencional de 0.05.
- **Implicaciones estratégicas y recomendaciones:** Los hallazgos permiten optimización basada en evidencia en 5 áreas: (1) *Inventario*: +60% en octubre para pico de noviembre, -30% en temporada baja (Q1); (2) *Marketing*: asignación del 60% del presupuesto anual a Q4, campañas semanales los jueves, segmentación geográfica (B2B para NL/SE/AU, premium para IT/CY/PT); (3) *Pricing dinámico*: +5-10% en Q4, -15-25% en Q1, diferenciación por país; (4) *RRHH*: +40% staff en Oct-Nov, priorización de días laborales, operación 5 días/semana en temporada baja; (5) *Forecasting*: implementación de SARIMA con período 365 días, reentrenamiento mensual, horizonte 3-6 meses. Impacto esperado: mejora 15-20% en precisión de forecast, reducción 20-30% en quiebres de stock, optimización 10-15% en costos operativos, incremento 5-10% en revenue anual.

Referencias

- [1] Chris Anderson. The long tail: Why the future of business is selling less of more. *Hyperion*, 2006.
- [2] Michael JA Berry and Gordon S Linoff. Data mining techniques: for marketing, sales, and customer relationship management. *John Wiley & Sons*, 2004.
- [3] George EP Box, Gwilym M Jenkins, Gregory C Reinsel, and Greta M Ljung. *Time series analysis: forecasting and control*. John Wiley & Sons, Hoboken, NJ, 5th edition, 2015.
- [4] Daqing Chen. Online retail II [Dataset], 2019. URL <https://doi.org/10.24432/C5CG6D>.
- [5] Daqing Chen, Sain L. Sain, and Kun Guo. Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management*, 19(3):197–208, 2012. doi: 10.1057/dbm.2012.17.
- [6] Dayi Chen, Sai Leung Sain, and Kun Guo. Data mining for the online retail industry: A case study of rfM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management*, 19(3):197–208, 2012.
- [7] A. J. Christy, A. Umamakeswari, L. Priyatharsini, and A. Neyaa. RFM ranking – an effective approach to customer segmentation. *Journal of King Saud University – Computer and Information Sciences*, 33(10):1251–1257, 2021. doi: 10.1016/j.jksuci.2018.09.004.
- [8] Robert B Cleveland, William S Cleveland, Jean E McRae, and Irma Terpenning. Stl: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1):3–73, 1990.
- [9] William Jay Conover. *Practical nonparametric statistics*. John Wiley & Sons, New York, 3rd edition, 1999.
- [10] David A Dickey and Wayne A Fuller. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366a):427–431, 1979.
- [11] Onur Doğan, Efe Ayçin, and Zeki Atıl Bulut. Customer segmentation by using RFM model and clustering methods: A case study in retail industry. *International Journal of Contemporary Economics and Administrative Sciences*, 8(1):1–19, 2018.
- [12] Shima Elghazaly, Heba Mahmoud, and Hesham Hefny. New RFM-D classification model for improving customer analysis and response prediction. *Egyptian Informatics Journal*, 24(2):269–281, 2023. doi: 10.1016/j.eij.2023.03.004.
- [13] Peter S Fader, Bruce GS Hardie, and Ka Lok Lee. Rfm and clv: Using iso-value curves for customer base analysis. *Journal of Marketing Research*, 42(4):415–430, 2005.
- [14] Ronald A. Fisher. *Statistical Methods for Research Workers*. Oliver and Boyd, Edinburgh, 1925.
- [15] Jiawei Han, Jian Pei, and Micheline Kamber. Data mining: concepts and techniques. *Elsevier*, 2011.
- [16] David C. Hoaglin and Boris Iglewicz. Fine-tuning some resistant rules for outlier labeling. *Journal of the American Statistical Association*, 82(400):1147–1149, 1987. doi: 10.1080/01621459.1987.10478551.
- [17] Rob J Hyndman and George Athanasopoulos. *Forecasting: principles and practice*. OTexts, 2nd edition, 2018. URL <https://otexts.com/fpp2/>.
- [18] Rob J Hyndman, Anne B Koehler, J Keith Ord, and Ralph D Snyder. *Forecasting with exponential smoothing: the state space approach*. Springer Science & Business Media, 2008.

- [19] Saravanan Kesavan, Vishal Gaur, and Ananth Raman. An empirical analysis of the effect of inventory on lost sales. *Management Science*, 60(7):1783–1796, 2014.
- [20] Maryam Khajvand, Kiyana Zolfaghar, Somayeh Ashoori, and Saeed Alizadeh. A review of the application of RFM model. *African Journal of Business Management*, 5(11):4199–4206, 2011.
- [21] Rahul Khandelwal. Customer segmentation in online retail: A detailed step-by-step explanation on performing customer segmentation in online retail dataset using python, focussing on cohort. Towards Data Science, January 1 2021. URL <https://towardsdatascience.com/customer-segmentation-in-online-retail-1fc707a6f9e6>. Accessed: 2025-09-29.
- [22] Henry B Mann and Donald R Whitney. On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1):50–60, 1947.
- [23] Nadim Nachar. The mann-whitney u: A test for assessing whether two independent samples come from the same distribution. *Tutorials in Quantitative Methods for Psychology*, 4(1):13–20, 2008.
- [24] Eric WT Ngai, Li Xiu, and Dorothy CK Chau. Application of data mining techniques in customer relationship management: A literature review and classification. *Expert Systems with Applications*, 36(2):2592–2602, 2009.
- [25] James W Taylor. Short-term electricity demand forecasting using double seasonal exponential smoothing. *Journal of the Operational Research Society*, 54(8):799–805, 2003.
- [26] Stephen J Taylor. Modeling financial time series. *World Scientific*, 2008.
- [27] Konstantinos K Tsipitsis and Antonios Chorianopoulos. Data mining techniques in crm: inside customer segmentation. *John Wiley & Sons*, 2009.
- [28] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley Publishing Company, Reading, MA, 1977.
- [29] Peter C Verhoef, Werner J Reinartz, and Manfred Krafft. Customer engagement as a new perspective in customer management. *Journal of Service Research*, 13(3):247–252, 2010.
- [30] Xiaozhe Wang, Kate Smith, and Rob Hyndman. Characteristic-based clustering for time series data. *Data Mining and Knowledge Discovery*, 13(3):335–364, 2006.
- [31] Jinghua Wu, Lin Shi, Weiping Lin, Qiulin Yang, Yanxia Liang, and Sheng Yang. An empirical study on customer segmentation by purchase behaviors using a RFM model and K-Means algorithm. *Mathematical Problems in Engineering*, 2020:8884227, 2020. doi: 10.1155/2020/8884227. [Retracted].